

文章编号: 1000-0747(202x)0x-0xxx-xx DOI: 10.11698/PED.20xx.xx.xx

基于残差U网络的地震叠前速度反演

黄艺冉^{1,4}, 潘畅^{1,2}, 王清振^{1,3}, 许建华^{1,2}

(1. 海洋油气勘探国家工程研究中心, 北京, 100028;

2. 南京师范大学计算机与电子信息学院/人工智能学院, 南京, 210023;

3. 中海油研究总院有限责任公司, 北京, 100028;

4. 波士顿大学计算机科学系, 美国波士顿, 02215)

基金项目: 海洋油气勘探国家工程研究中心开放基金课题“基于深度学习的地震速度新方法研究”;

国家自然科学基金面上项目“大规模多标签分类中内嵌恢复算子的标签选择算法研究”(62076134)

摘要: 速度是油气地震勘探中最关键的物性参数之一, 贯穿着地震勘探中的数据采集、处理与解释的全过程。全波形反演是目前高精度速度成像的主力技术, 但仍面临多解性、周期性跳变、计算效率低等困难。近几年, 借助于以深度学习为代表的机器学习技术的成功应用和快速发展, 基于深度学习的速度反演技术成为一种新的备选方法。但是, 如何根据非常有限的训练样本构建一个合适的反演网络结构仍然是当前面临的主要挑战。本文将多炮地震记录到二维速度剖面的反演问题归结为异质图像到图像的像素级回归问题, 并将深度学习的两个代表性成功网络(残差卷积网络与U网络)两者相融合, 有效地建立低层到高层的信息传递通路, 从而构建一个基于残差U网络的地震叠前速度反演方法。在岩体、断层、层状三个合成数据集上, 通过定量比较与可视化分析, 实验验证了我们所提出方法是有效的, 并优于已有单纯基于U网络的FCNVMB反演网络。

关键词: 油气勘探; 地震勘探; 速度反演; 深度网络; 残差网络; U网络

中图分类号: TE122.3 文献标识码: A

Seismic prestack velocity inversion method based on residual U-net

HUANG Yiran^{1,4}, PAN Chan^{1,2}, WANG, Qingzhen^{1,3}, XU Jianhua^{1,2}

(1. National Engineering Research Center of Offshore Oil and Gas Exploration, Beijing 100028, China;

2. School of Computer and Electronic Information/Artificial Intelligence, Nanjing Normal University, Nanjing 20023, China;

3. CNOOC Research Institute Ltd, Beijing 100028, China;

4. Department of Computer Science, Boston University, Boston, MA 02215, USA)

Abstract: Velocity is one of the most important geophysical parameters in seismic exploration, which is used in the entire stage of seismic exploration from acquisition, processing to interpretation. Full waveform inversion has become a key technique for high-resolution velocity imaging, which usually is criticized in three aspects: non-unique solution, cycle-skipping and high computational cost. Recently, due to many successful applications and fast developments in machine learning techniques, specially in deep learning, some inversion approaches based on deep neural networks are chosen as an alternative strategy for full waveform inversion. However, with a limited number of training instances, it is still challenging for constructing a proper inversion network architecture. In this paper, we regard two-dimensional seismic pre-stack velocity inversion from seismic multi-shot records to two-dimensional velocity profiles as a heterogeneous image-to-image pixel-level regression and fuse two representative deep networks (residual network and U-net) to build several effective information pathways from low-levels to high levels. Therefore, a novel seismic pre-stack velocity inversion method based on residual U-Net is proposed. On three synthetic data sets (salt body, faulted and layered), via quantitative comparison and visual analysis, we validate that our proposed method is effective and performs better than FCNVMB based on pure U-net, experimentally.

Key words: Oil and gas exploration; seismic exploration; velocity inversion; deep neural network; residual network; U-net

引用: 黄艺冉, 潘创, 王清振, 等. 基于残差U网络的地震叠前速度反演[J]. 石油勘探与开发, 202x, 4x(x): xxx-xxx.

HUANG Yiran, PAN Chan, WANG Qingzhen, et al. Seismic Prestack Velocity Inversion Based on Residual U-net [J]. Petroleum Exploration and Development, 202x, 4x(x): xxx-xxx.

0 引言

地震勘探是当今油气勘探的主力技术^[1,2]，地表采集到的地震数据通过处理、解释后可以有效地推断出地下油气层的结构、构造与物性参数。随着勘探开发难度的不断加大，促使地震勘探的成像技术向高精度方向发展。近四十年来，其中一项引入瞩目的技术就是全波形反演。全波形反演利用叠前地震波场的运动学与动力学特性重构地层的结构与物性参数，具有发现复杂地质条件下构造与物性的能力^[3-7]。它的基本技术路线是：借助于波动方程正演过程，利用梯度下降类型的优化技术最小化观测数据与合成数据之间的残差，寻找出最佳物性参数模型。现在学术界，将这类经典全波形反演技术称之为物理引导的全波形反演^[8,9]。

自上世纪八十年代，法国学者Tarantola等^[10,11]提出全波形反演技术后，该技术得到长足的进步，逐步成为油气勘探与开发的常规技术^[3-7]。但是，该项技术仍存在三个方面的局限性：多解性、周期性跳变、高计算复杂性。其原因包括：高度非线性的目标函数、梯度类优化算法的慢收敛性、低频信息的缺少等^[8]。除了革新经典的全波反演方法外，研究人员也在积极寻找可能的替代技术。

1994年法国学者Tarantola等利用反向传播网络BP进行叠前地震数据的一维速度方法^[12]，1996国内学者陆文凯等^[13]开展叠后波阻抗反演研究。自此之后，研究人员使用过不同的机器学习算法，如支持向量机等^[14]，但是一直处于一个尝试阶段。近10年来，以深度神经网络为代表的机器学习技术得到迅速的发展，并成功应用于图像理解、自然语言处理等领域。同时吸引大批地球物理研究人员的关注^[15,16]，尝试用深度网络求解全波形反演问题^[8]，提出基于数据驱动的全波形反演新范式。机器学习的基本过程：采集样本、标注样本、建立机器学习模型和测试模型的性能。在地震勘探中，对于采集到的地震记录，专家并不能标注其性质（如速度模型），从而无法套用机器学习标准流程。为此，采用“本末倒置”的方式，先设计各种速度模型（标签），然后通过正演过程合成对应的地震记录（样本）。根据地震数据的合成技术，可以分成基于褶积模型的一维物性参数反演和基于波动方程正演的二维或者三维物性参数（如速度）^[8,9]，后者更接近于经典的全波形反演，也是本文关注的研究内容：地震叠前多炮记录的二维速度反演。

从机器学习的角度来看，二维速度反演可以看作

多炮地震记录（三阶张量）到二维速度剖面（矩阵）的非线性多输出回归问题^[17,18]。在多输出回归中，多个输出排列成一个向量，此时，可以采用典型的卷积网络CNN。2018年Arayo-Polo等学者^[19]提出首个用于全波形反演的深度网络，前端是卷积层，后端是全连接层，并将多炮道集处理成速度谱。考虑到速度剖面的二维形式，全波形反演最接近的机器学习问题是对应于分类问题的图像分割，其最典型网络结构是编码-解码结构，前者逐步缩减图像的高度和宽度、增加通道数，后者刚好相反。在FCNVMB^[20]中，采用U网络^[21]进行速度反演，该网络在编码-解码结构上，添加从低层到高层的特征图拼接连接，便于信息的传递。InversionNet^[22]也采用类似的编码-解码结构，但是两者之间是一个全连接层。生成式对抗网络GAN由生成子网络和判断子网络构造，通过竞争学习到达最优，其中生成网络可以用于生成逼真的合成图像，VelocityGAN^[23]用生成网络作为反演网络。

（更详细的文献评述见后面的相关工作）。

虽然近五年来出现大量的研究成果^[8,9]，推动数据驱动的全波形反演技术的发展，但是这类方法的成功依赖于合适的网络结构，合理的网络组件，因此设计和实现更合理的网络结构仍然是一个值得深入探索的问题。用于图像分割的U网络^[21]建立从低层编码器到高层解码器的信息转递通路，提高网络的性能，据此建立FCNVMB^[20]。对于卷积网络^[24]，随着层数的不断增加，会面临着优化困难：出现梯度消失、收敛缓慢。残差网络^[25]引入残差结构，由3卷积层构成，其输入或者第一层的输出叠加到最后一层，引入短路连接传递低层到高层的信息，提高网络性能并加速优化过程。本文以U网络作为基本网络结构，在上面添加残差结构，构造出残差U网络ResUnet，用于地震叠前速度反演，充分利用两个网络的优点，建立从低层到高层的信息传递通路，提高反演性能。在岩体、断层、层状数据集上，我们的网络要优于FCNVMB^[20]，实验验证了我们提出速度反演网络的有效性。

1 准备工作

我们先列出本文用到的数学符号。依据^[26]，张量是一个多维数组，其阶数是维度数，一般情况三阶及其以上才称为张量，用手写体大写字母来表示，如 \mathbf{X} 。一阶、二阶张量就退化到向量和矩阵，分别小写、大写黑体字母表示，如 \mathbf{x} 和 \mathbf{X} 。零阶张量则为标量，用小写、大写斜体字母来表示，例如 n 和 N 。

假设速度剖面的坐标系由沿水平地面的 x 轴和垂直向下的 z 轴构成。一个垂直深度为 D_z 和水平距离为 D_x 的速度剖面，利用网格化间隔 D_g 离散成一个速度矩阵 $\mathbf{V} \in \mathbb{R}^{+N_z \times N_x}$ ，其中 N_z 和 N_x 分别为两个方向的网格点数、 \mathbb{R}^+ 表示正的实数域。固定检波点位置，移动炮点，产生不同的炮记录，构成一个多炮地震记录的三阶张量 $\mathbf{X} \in \mathbb{R}^{N_t \times N_r \times N_s}$ ，其中 N_t 、 N_r 、 N_s 分别表示地震记录的时间采样点数、检波器个数和激发炮数。在后面的试验中，每一炮地震剖面利用有限差分法求解二维声波波动方程得到。




图1 地震叠前正演与反演示意图

如图1所示，从二维速度剖面及其对应的多炮地震记录的正反演过程，形式上可以表示为

$$\mathbf{X} = f(\mathbf{V}) \quad (1)$$

$$\mathbf{V} = f^{-1}(\mathbf{X}) \quad (2)$$

其中 f 和 f^{-1} 为正、反演算子。在传统的全波形反演中，一个多炮记录直接反演出其对应的速度剖面，不同的地震记录的反演过程是独立的。但是，对于数据驱动的全波形反演，则需要一个预先准备好的训练样本集：

$$\{(\mathbf{X}_1, \mathbf{V}_1), \dots, (\mathbf{X}_N, \mathbf{V}_N)\} \quad (3)$$

其中 N 为训练样本数。从统计学角度来看，传统的物理引导的全波形反演是基于个体的建模方法，而数据驱动的全波形反演是基于群体的建模技术。

2 相关工作

数据驱动的全波形速度反演利用机器学习技术求取从地震叠前记录到速度的非线性反演算法 f^{-1} 。当前主要使用深度网络中的卷积网络、自编码器网络、生成式对抗网络及其它们的各种组合。

传统的多层感知器是典型的前馈网络结构，由若干全连接层构成，且普遍使用正切和对数S型、线性转换函数，实现分类与回归功能。在保留最后一、二个全连接层后，卷积网络则用卷积层代替多层感知器中前面的全连接层。对于二维卷积来说，可以直接输入彩色图像。自编码器由编码器、解码器串联而成，

前者实现压缩功能，后者完成解码功能，使得输出尽可能接近于输入。当前这些网络的目标函数定义为实际输出与期望输出的平方误差加上L1或者L2的正则项，且广泛使用自适应矩估计（Adaptive moment estimation, ADAM）进行优化。下面我们根据网络结构及其功能对已有的代表性研究成果进行分析与概述。

2.1 多炮地震记录到一维速度向量的反演网络

2018年Araya-Polo等学者开创性地使用深度网络来实施二维速度反演^[19]。先将每一个多炮记录进行速度谱分析，获得三维数据体，再将二维速度排列成一维向量。反演网络由四个卷积块（12个三维卷积层）、两个全连接层构成。在^[27]中，将炮记录转换成零偏移距炮集，其网络是二个卷积层和四个全连接层。这两项研究本质上全波形反演看成一个多输出回归问题，存在着两个问题，一是输出层神经元个数多，如一张140*180的速度剖面的维数25K，二是忽视速度剖面的二维结构信息。

2.2 多炮地震记录到二维速度剖面的反演网络

用卷积层替代卷积网络中的全连接层，则构造出全卷积网络，最初用于图像分割，实现图像像素级的分类。将离散输出转换成连续输出，并采用自编码器结构后，构造一个10个卷积层和8个转置卷积层的全卷积网络用于全波形速度反演^[28]。在文^[20]中，引入图像分割中U网络构成23卷积层的全波形反演网络，特殊之处是从低层特征到高层特征的跳层拼接连接。当采用偏移图像作为输入，文^[29]采用24层的U网络进行速度反演。

反演网络InversionNet^[22]采用更特殊的自编码器结构，在编码器（四个卷积层）与解码器（五个卷积层）之间插入一个全连接层。然后这一研究被推广到多尺度反演，包含低、高分辨率网络^[30]和三维速度反演网络^[31]。

前面提及的网络大多在上世纪八、九十年代已有雏形^[24]，主要的进步是转换函数、优化技术、随机权值切除等。生成式对抗网络是2014年提出的全新深度网络^[32]，由生成器和判别器子网络组成。通过两个子网络不断对抗学习，生成器尽可能产生尽可能“以假乱真”的假样本，而判别器尽力检测出真假样本。训练好的生成器经常用于图像生成，这一功能被^[23]用于二维速度反演，其生成器由32个卷积层的编码器构成。这一网络相对于前面提到的反演网络，性能要略微逊色。

由于速度反演的样本数非常有限，这类方法的网

络结构普遍较小, 卷积层数小于32。

2.3 残差U网络的应用概括

由于U网络^[21]在图像分割中的成功应用, 随后被广泛应用各种图像分割^[33]。深度网络普遍采用基于梯度的各种优化技术, 但是随着深度的增加, 会出现梯度消失或者爆炸现象, 导致优化过程的失败。He等人提出残差网络^[25], 其残差块将输入叠加到最后一个卷积层的输出, 以保障梯度不出现异常, 加速训练过程。文^[34]首次将残差网络与U网络相结合, 构成出残差U网络, 用于道路的抽取。随后很多研究人员, 构造略有差别各种残差U网络, 仍然主要用于图像分割问题^[35]。与油气勘探相关的研究, 我们查阅到断层识别和地震去噪两项应用。关于断层识别, 文^[36]中U网络中的每一卷积块都是三个卷积层的残差块, 而文^[37]中利用残差U网络构造出一个具有嵌套结构的U网络, 这两项研究本质上仍属于图像分割的范畴^[38]。地震去噪^[39]可以看作同质图像到图像的回归问题, 且输入与输出具有相同的大小。在我们研究中, 我们将残差U网络用于叠前地震速度反演, 广义上来说, 属于异质图像到图像的回归问题, 与去噪的不同之处有, 第一、输入为多通道的多炮地震记录, 输出单通道的速度剖面, 具有完全不同的物理含义, 属于异质图像; 第二、输入、输出的大小(高度、宽度、通道数)不同, 需要在网络结构上考虑到这种大小差异。

3 基于残差U网络的二维速度反演

这一部分介绍我们提出的残差U网络的结构及其关键参数设置。

3.1 基于残差U网络的二维速度反演网络的结构

在深度学习中, 除了输入、输出外, 将隐层的输出称之为特征图。自编码器由编码器和解码器串联构成, 其编码器逐层减小特征图的高度和宽度、增加通道数, 解码器刚好相反, 其目标使输出尽可能逼近输入。U网络^[21]是一种扩展的编码-解码结构, 两者之间插入一个卷积连接块。编码器和解码器分割成若干卷积块, 并将编码器的卷积块输出拼接到对称位置解码器的卷积块之后, 在高层信息中加入低层信息, 提高网络的性能, 是图像分割的代表性网络。残差网络将大量的卷积层分割成普通卷积和残差卷积块, 后者的卷积块将输入叠到最后一个卷积层的输出, 其目的是避免梯度消失现象、加速训练过程, 是一个典型的分类网络。本文中, 我们将残差网络中残差卷积块取代U网络的普通卷积块, 构成一个残差U网络ResUnet, 并在输出设置成正实数, 用于地震叠前速

度反演。

残差U网络的结构如图2所示, 将多炮地震记录排列成一个三阶张量, 作为网络的输入, 输出是二维速度剖面。

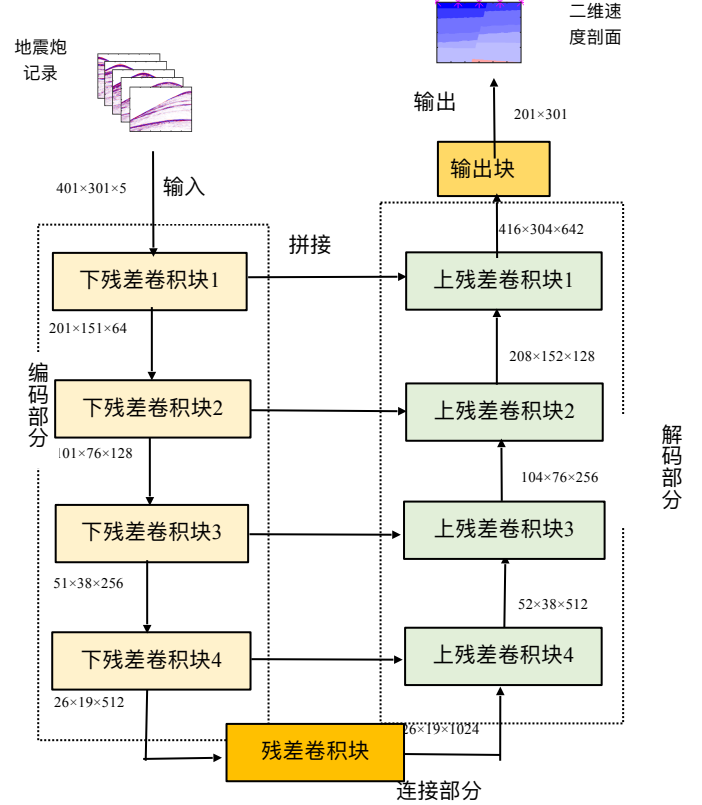


图2 基于残差U网络的速度反演网络结构

图2的残差U网络有四类部件: 下残差卷积块、残差卷积块、上残差卷积块和输出块, 我们标出每一模块的输出特征图大小: 高度、宽度和通道数, 从编码部分到解码部分的水平箭头表示U网络的拼接连接。关于核个数或者通道数, 在编码器部分从64逐步倍增到512, 连接部分为1024, 而解码部分则逐步倍减。根据前面的训练集(3), 网络的目标函数定义均方误差:

$$E = \frac{1}{2} \sum_{i=1}^N \| \mathbf{v}_i - f^{-1}(\mathbf{x}_i) \|_F^2 \quad (1)$$

其中, F 指矩阵的Frobenius范数。我们用Pytorch自带ADAM最小化器优化上述目标函数。

3.2 网络主要部件的结构设计和参数设置

这里我们给出图2中四个部件的结构与参数。

残差卷积块由四个卷积层构成, 如图3所示, 其中第一卷积层的输出叠加到第四个卷积层, 这样的设计保证叠加操作的两个特征图具有相同的大小。另

外，我们采用四个卷积层，而不是最常用的三层^[34]，来提高网络性能。在深度学习中，所谓卷积层经常包含其后接的批归一层和激活函数层（如，矫正线性单元ReLU^[40]）。这一残差卷积块不改变特征图的高度和宽度，通道数由第一个卷积层确定。图3括号的参数为核、步幅、加边大小。

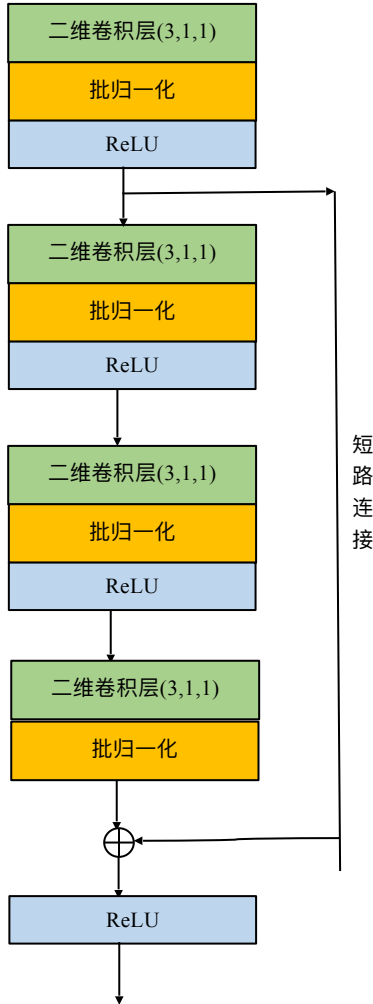


图3 残差卷积块的结构与参数

下残差卷积块由一个残差卷积块加上一个最大池化层构成，如图4，其中的池化层将特征图的高度和宽度减半，对应的参数表示核、步幅、加边大小。




图4 下残差卷积块的结构与参数

上残差卷积块包含一个转置卷积、加边拼接操作

和残差卷积块，如图5所示。其中的转置卷积扩增高度和扩大、减小通道数；加边拼接操作先对左侧输入补零加边使得高度、宽度相同，再拼接在转置卷积层输出之后。




图5 上残差卷积块的结构与参数

地震炮记录通过整个U型结构后，最后一个上卷积块输出的高度与宽度（ 416×304 ），如图2所示，与地震炮记录的时间采用点数和道数（ 401×301 ）相近，而二维速度剖面大小为 201×301 ，我们在中心位置裁剪出一个大小 $201 \times 301 \times 64$ 的特征图，再经过一个核数为1的二维卷积层，获得 201×301 的速度剖面，输出块的结构为图6所示。




图6 输出块的结构与参数

根据这一部分的网络结构设计，我们ResUnet共有37个二维卷积层和4个转置卷积层，要略深于代表性网络23层的FCNVMB^[20]。

4 实验验证

4.1 数据集和比较网络

在本文研究中，我们使用三个合成数据集：岩体、层状和断层，见表1。岩体数据是从GitHub下载的^[41]，其中包含1600个训练、100个测试速度模型，但是没有对应的地震炮记录，附带有基于Python和Pytorch的FCNVMB的源码。后两个数据集是我们根据文献的基本思想^[22,23,27,29]，结合岩体数据集的参数设置，重新设计的断层、层状速度模型。

岩体速度模型垂直深度、地面水平距离分别为2和3千米，其中包含5-12个弯曲界面的地层，速度值随深度增加的2.0至4.0千米/秒，在任意位置嵌入一个速度为4.5千米/秒的岩体。利用10米的网格化距离，速度剖面被离散成大小为 201×301 的矩阵。类似地，设置

倾斜、弯曲地层界面，构造出层状速度模型。再随机地确定断层线、滑动方向和距离，从层状速度模型生成断层模型。

表1、三个实验数据集的概括

数据集	训练样本数	测试样本数
岩体	1600	100
层状	1800	200
断层	1800	200

利用有限差分法求解声波波动方程，我们获得五炮地震记录。炮点位置被分别安放在地面0、750、1500、2250、3000米处，检波点以10米的间距从0至3000米均匀安置，时间采样间隔为1毫秒，生成的地震记录为大小为 $2001 \times 301 \times 5$ 的三阶张量。图7显示其中速度模型及其对应的多炮地震记录，除了切成强直达波外，我们没有施加任何数据处理。为了与FCNVMB公平比较，在时间上我们也进行下采样，时间点数从2001约简到401。

对应两个网络（ResUnet和FCNVMB），我们使用相同的训练参数：循环次数为100，学习率0.001，批大小10，且都未使用正则项。

为了评价和比较不同的网络的反演性能，我们采用四个评估指标包括：Pearson相关系数（PCC）、均方根误差（RMSE）、峰值信噪比（PSNR）、结构相似性（SSIM）。前两个指标主要用于评价多输出回归^[18,19]，后两个指标主要用于评价图像质量^[42,43]，除了RMSE外，其余三个指标值越大越好，如表2中箭头所示。

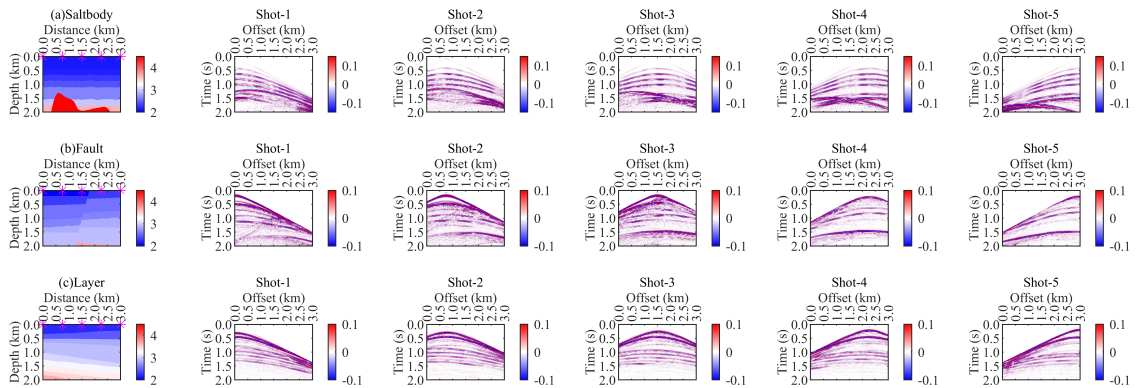


图7 三类速度模型及其对应的五炮炮集的示例

4.2 网络的收敛性分析

为了验证ResUnet和FCNVMB的网络结构和参数设置是否合理,我们分析它们的收敛性。将岩体1600个训练样本划分成1500个训练样本和100个检验样本。对于总共100次循环,保存5,10,...,95,100次循环时的网络模型,然后分别对训练训练和检验样本计算均方根误差RMSE和结构相似性SSIM指标,画出收敛性曲线,如图8所示。可以观察到:第一、随着循环次数的增加, RMSE曲线逐步减小, SSIM曲线逐步增加,总体上具有好的收敛性;第二、ResUnet的迭代收敛率要比FCNVMB快;第三、训练与测试指标值之差非常小,说明没有过学习现象;第四、整体上ResUnet的性能优于FCNVMB。这一收敛性分析结果说明:两个深度网络的结构和参数设置是合理的。




图8 ResUnet和FCNVMB的收敛性分析

4.3 实验结果的定量比较

我们利用三个数据集的所有训练样本分别对网络进行训练,然后用对应的测试样本对网络进行性能评估。

图9显示岩体数据集100个测试样本的四个指标的具体值,在所有样本上,我们ResUnet都优于FCNVMB。

在三个数据集,我们计算每一个指标的平均值与标准差,如表2所示,其中向下、向上箭头表示指标值小、值大对应于好的预测性能。在所有的平均值上,我们算法都优于FCNVMB。对于标准差,在岩体与断层的峰值信噪比上,我们算法的标准差略偏大。为了验证这种性能提高是不是显著的,在显著水





图9 岩体数据集100个测试样本的四个评价指标值


表2 两个反演算法在三个数据集的评价指标值

评价指标	FCNVMB	ResUnet	T检验
岩体			
相关系数 ↑	95.51±2.25	97.50±1.25	优
均方根误差 ↓	213.28±49.21	159.14±40.67	优
峰值信噪比 ↑	26.70±1.88	29.28±2.05	优
结构相似性 ↑	91.55±1.63	93.27±1.16	优
层状			
相关系数 ↑	95.48±3.70	98.11±1.12	优
均方根误差 ↓	112.23±43.66	85.93±35.20	优
峰值信噪比 ↑	32.57±2.83	34.88±2.78	优
结构相似性 ↑	96.24±1.21	97.07±1.03	优
断层			
相关系数 ↑	95.70±2.61	98.02±0.86	优
均方根误差 ↓	139.15±43.49	91.07±27.79	优
峰值信噪比 ↑	30.53±2.33	34.21±2.35	优
结构相似性 ↑	95.22±1.20	96.28±1.06	优

平 $\alpha=0.05$ 设置下,我们利用t-检验比较每一个指标,其结果列出表2的最后一列,其中“优”表示我们算法要显著优于FCNVMB。




(1)岩体速度剖面的比较




(2)对应于第151道位置的速度曲线比较

图10 岩体数据集两个代表性的预测结果比较



(1)层状速度剖面的比较



(2)对应于第151道位置的速度曲线比较

图11 层状数据集两个代表性的预测结果比较

获

得清晰的速度剖面，比FCNVMB更接近于原始地震速度剖面。为了更精细的观察预测结果，我们抽出第151道位置的速度曲线，在图10中，我们ResUnet获得逼近原始速度曲线，特别是右小图中的高速岩体；在图

5结论

以深度学习为主轴的人工智能技术发展地震叠前全波形反演提供一种可选择的技术路线。本文结合深度学习中的两个成功的深度网络（U网络和残差网络），提出一种残差U网络，用于地震叠前速度反演。在三个合成数据集上，通过与基于单纯U网络的参考文献：

1. 陆基孟, 王永刚. 地震勘探原理(第三版)[M]. 北京: 中国石油大学出版社, 2010.
LU Jimeng, WANG Yonggang. The Principle of Seismic Exploration (3rd Edition)[M]. Beijing, China University of Petroleum Press, 2010.
2. 张白林, 潘树林, 尹成. 地震勘探资料数字处理方法(第二版)[M]. 北京: 石油工业出版社, 2012.
ZHANG Bailin, PAN Shulin, YIN Cheng. Digital Processing Methods for Seismic Exploration Data (2nd Edition)[M]. Beijing, Petroleum Industry Press, 2011.
3. VIRIEUX J, OPERTO S. An overview of full-waveform inversion in exploration geophysics [J]. Geophysics, 2009, 74(6): WCC127-152.
4. VIRIEUX J, ASNAASHARI A, BROSSIER R, et al. An introduction to full waveform inversion. In Geophysical References Series:

11、12上，ResUnet预测的速度曲线也更好地拟合原始真实速度曲线。这些可视化分析也验证了我们所提出深度反演网络的有效性。

FCNVMB进行详细的实验比较，从定量比较、可视化分析两个角度，说明我们所提出深度反演网络的有效性。我们本项研究为数据驱动的全波形反演提供一种新的深度网络结构，推动深度学习在油气勘探领域的更广泛的应用。

我们下一步研究将用验证更多数据集进一步验证本文提出深度网络的性能。

- Encyclopedia of Exploration Geophysics [M], 2014, R1-1--1-40.
5. YAO G, WU D, WANG S-X. A review on reflection-waveform inversion [J]. Petroleum Sciences, 2020, 17(2): 334-351
6. 杨午阳, 王西文, 雍学善, 等. 地震全波形反演方法研究综述[J]. 地球物理学进展, 2013, 28(3): 766-776.
- YANG Wuyang, WANG Xi-wen, YONG Xue-shan, et al. The review of seismic full waveform inversion method [J]. Progress in Geophysics, 2013, 28(2): 766-776
7. 杨勤勇, 胡光辉, 王立歆. 全波形反演研究现状及其发展趋势[J]. 石油物探, 2014, 53(1): 77-83.
- YANG Qinyong, HU Guanghui, WANG Lixin. Research status and development trend of full waveform inversion[J]. Geophysical Prospecting for Petroleum, 2014, 53(1): 77-83.
8. ADLER A, ARAYO-POLO M, POGGIO T.

9. 王竟仪, 王治国, 陈宇民, 等. 深度人工神经网络在地震反演中的应用进展[J]. 地球物理学进展, 网络首发: <https://kns.cnki.net/kcms/detail/11.2982.P.2022829.0816.002.html>.
10. Wang Jingyi, WANG Zhiguo, CHEN Yumin, et al. Deep artificial neural network in seismic inversion [J]. Progress in Geophysics, online: <https://kns.cnki.net/kcms/detail/11.2982.P.2022829.0816.002.html>.
11. TARANTOLA A. Inversion of seismic reflection data in the acoustic approximation [J]. Geophysics, 1984, 49(8): 1259-1266.
12. GAUTHIER O, VIRIEUX J, TARANTOLA A. Two-dimensional nonlinear inversion of seismic waveform: numerical results [J]. Geophysics, 1986, 51(7): 1387-1403.
13. ROTH G, TARANTOLA A. Neural networks and inversion of seismic data [J]. Journal of Geophysical Research: Solid Earth, 1994, 99(B4), 6753-6768.
14. 陆文凯, 李衍达, 牟永光. 误差反传播神经网络法地震反演[J]. 地球物理学报, 1996, 39(S1), 292-301.
15. LU Wen-Kai, LI Yan-Da, MU Yong-Guang. Seismic inversion using error-back-propagation neural network[J]. Chinese Journal of Geophysics, 1996, 39(S1): 292-301.
16. 杨培杰, 印兴耀. 基于支持向量机的叠前地震反演方法[J]. 中国石油大学学报(自然科学版), 32(1), 37-41.
17. YANG Pei-Jie, YIN Xing-yao. Prestack seismic inversion method based on support vector machine [J]. Journal of China University of Petroleum, 2008, 32(1): 37-41.
18. BERGEN K J, JOHNSON P A, de Hoop M V, et al. Machine learning for data-driven discovery in solid earth geoscience [J]. Science, 2019, 363(6438): article-eaau0323.
19. KARPATNE A, EBERT-UPHOFF I, RAVELA S, et al. Machine learning for the geosciences: challenges and opportunities [J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 31(8): 1544-1554.
20. BORCHANI H, VARANDO G, BIELZA C, et al. A survey on multi-output regression [J]. WIREs Data Mining and Knowledge Discovery, 2015, 5(5): 216-233.
21. XU D, SHI Y, TSANG I W, et al. Survey on multi-output learning [J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(7): 2409-2429.
22. ARAYA-POLO M, JENNINGS J, ADLER A, et al. Deep learning tomography [J]. The Leading Edge, 2018, 37(1): 58-66.
23. YANG F, MA J. Deep-learning inversion: A next generation seismic velocity-model building method [J]. Geophysics, 2019, 84(4): R583-599.
24. RONNEBERGER O, FISCHER P, BROX T. U-net: convolutional networks for biomedical image segmentation [C]. Proc. MICCA, vol. LNCS-9351, 2015, pp. 234-241.
25. Wu Y, Lin Y. Inversionnet: an efficient and accurate data-driven full waveform inversion [J]. IEEE Transactions on Computational Imaging, 2020, 6:419-933.
26. ZHANG Z, LIN Y. Data-driven seismic waveform inversion: A study on the robustness and generalization [J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(10): 6900-6913.
27. GOODFELLOW I, BENGIO Y, COURVILLE A. Deep Learning [M]. Cambridge MA, USA: MIT Press, 2016.
28. HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]. Proc. IEEE CVPR, 2016, pp. 770-778.
29. 张贤达. 矩阵分析与应用(第二版)[M]. 北京: 清华大学出版社, 2013.
30. ZHANG Xianda. Matrix Analysis and applications [M]. Beijing: Tsinghua University Press, 2013.
31. MAO B, HAN L-G, FENG Q, et al. Subsurface velocity inversion from deep learning-based data assimilation [J]. Journal of Applied Geophysics, 2019, 167: 172-179.
32. WANG W, YANG F, MA J. Velocity model building with a modified fully convolutional network [C]. Proc. SEG Tech. Program Expanded Abstracts, 2018, pp. 2086-2090.
33. ZHANG W, GAO J. Deep-learning full-waveform inversion using seismic migration images [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: article-5901818.
34. FENG S, LIN Y, WOHLBERG B. Multiscale data-driven seismic full waveform inversion with field data study [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: article-4506114.
35. ZENG Q, FENG S, WOHLBERG B, et al. Inversionnet3d: efficient and scalable learning for 3D full waveform inversion [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: article-4506816.
36. GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial networks[C]. Proc. NIPS, 2014, pp. 2672-2680.
37. DU G, GAO X, LIANG J, et al. Medical image segmentation based on U-net: a review [J]. Journal of Imaging Science and Technology, 2020, 64(2): article-020508.
38. ZHANG Z, LIU Q, WANG Y, et al. Road extraction by deep residual U-net [J]. IEEE

- Geoscience and Remote Sensing Letters, 2018, 15(5): 749-753.
35. SIDDIQUE N, PAHEDING S, ELKIN C P, et al. U-Net and Its Variants for Medical Image Segmentation: A Review of Theory and Applications [J]. IEEE Access, 2021, 9: 82031-82057.
 36. LIU N, HE T, TAIN Y, et al. Common-azimuth seismic data fault analysis using residual unet [J]. Interpretation, 2020, 8(3):SM25-37.
 37. GAO K, HUANG L, ZHANG Y. Fault detection on seismic structural images using a nested residual u-net [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: article-4502215.
 38. MINAEE S, BOYKOV Y, PORIKLI F, et al. Image segmentation using deep learning: a survey [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(7): 3523-3542.
 39. Zhong T, Cheng M, DONG X, et al. Seismic random noise suppression by using deep residual U-net [J]. Journal of Petroleum Science and Engineering, 2022, 209: article-109901.
 40. 张学工, 王小我. 模式识别(第四版)[M]. 北京: 清华大学出版社, 2021.
- ZHANG X, WANG X. Pattern Recognition (4th edition)[M]. Beijing: Tsinghua University Press, 2021
41. <https://github.com/YangFangShu/FCNVMB>.
 42. WANG Z, BOVIK A C, SHEIKH H R. Image quality assessment: from error visibility to structural similarity [J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.
 43. SEIADI D I M. PNSR vs SSIM: imperceptibility quality assessment for image steganography [J]. Multimedia Tool and Applications, 2021, 80(28/29): 8423-8444.
- 第一作者简介: 黄艺冉 (2000-), 女, 河南新乡人, 学士, 原为南京师范大学计算机与电子信息学院/人工智能学院本科生, 现为美国波士顿大学科学与艺术学院计算机科学系硕士生, 主要从事人工智能、大数据的研发, 地址: Department of Computer Science, School of Arts & Sciences, Boston University, 705 Commonwealth Avenue, Boston, MA 02215, USA。E-mail: yruhuang@bu.edu
- 第二作者简介: 潘创 (1998-), 男, 安徽淮北人, 学士, 南京师范大学计算机与电子信息学院/人工智能学院硕士生, 主要从事深度学习及其应用的研发。地址: 南京市栖霞区文苑路1号, 邮政编码: 210023。E-mail: 202243027@stu.njnu.edu.cn
- 第三作者简介: 王清振 (1983-), 男, 山东邹城人, 硕士, 中海油研究总院有限责任公司高级工程师, 主要从事地震资料解释、属性分析、反演等方面技术研究及相关软件研发工作。地址: 北京市朝阳区太阳宫南街6号海油大厦A-1005室, 邮政编码: 100028。E-mail: wangqzh2@cnooc.com.cn
- 联系作者简介: 许建华 (1962-), 男, 浙江长兴人, 博士, 南京师范大学计算机与电子信息学院/人工智能学院教授, 主要从事机器学习、模式识别、神经网络的理论与应用研究。地址: 南京市栖霞区文苑路1号, 邮政编码: 210023。E-mail: xujianhua@njnu.edu.cn / xujianhua1999@tsinghua.org.cn
- 收稿日期: 2022-10-12 修回日期: 2022-xx-xx
- (编辑 xxx)