

南京师范大学

毕业设计(论文)

(2022 届)



题目：基于深度卷积网络的地震速度反演方法研究

学院：计算机与电子信息学院/人工智能学院

专业：计算机科学与技术

姓名：黄艺冉

学号：21180639

指导教师：许建华

南京师范大学教务处 制

摘 要

随着地下石油和天然气资源的持续勘探和开采，易生产区的探索不断接近饱和，这使得开展更复杂地区的石油和天然气勘探工作更为困难，对地震勘探技术来说是一个更严重的挑战。地震勘探的核心是地震波，精准的速度模型是地震勘探技术的重要组成部分。但是传统方法较为局限，不仅耗时而且计算昂贵，并且他们严重依赖人为的交互。将深度学习引入地震勘探领域，不仅可以大幅度减少传统方法中大量的重复性工作，并且速度快、效率高。

本论文将确定地下速度参数问题转化为地震信号到速度的多输出回归问题。实验从地震剖面数据的基础上通过自发产生的地震信号生成地震速度数据，分别作为输入数据和输出数据。基于深度卷积网络算法，本论文提出了 UnetRes1 和 UnetRes2 算法，在原始 U-net 基础上加入残差网络学习优化网络结构，对地震信号生成的地震数据到地震剖面数据进行端到端的有监督学习，直接从原始地震信号图建立速度模型。在训练阶段，网络建立了一个从多点地震数据到相应速度模型的非线性映射。在测试阶段，训练完成的网络可估计新输入地震数据的速度模型。

本论文总结出：UnetRes2 的效果要比 UnetRes1 和 U-net 更好，而 UnetRes1 远不如 U-net。U-net 深度卷积网络通过其压缩和扩展路径、跳转连接等特点可以很好地提取图片中的特征并且保留一定原始图像的信息，在每层卷积网络中加入残差学习可以一定程度上的降低训练损失，避免随着神经网络层数的增加出现训练退化问题，且残差网络中输入端跳转的卷积层数越多效果越好。所以，一旦建立了良好的深度卷积网络，地震反演的计算时间不仅可以大大减少同时可以得到较为准确的预测结果。

关键词：速度反演；地震勘探；深度卷积神经网络；残差网络。

Abstract

With the continuous exploration and mining of underground oil and natural gas resources, the exploration of the easy production area is constantly limited, which makes it more difficult to carry out more complex region of exploration work, and it becomes a more serious challenge for earthquake exploration technology. The core of seismic exploration is the seismic wave, so accurate speed model is an important part of seismic exploration technology. However, the traditional methods are constrained, time consuming and costly, and they seriously rely on people's interaction. Introducing deep learning into the field of seismic exploration, which can significantly reduce a large number of repetitive work in traditional methods with quick speed and high efficiency.

According to this thesis, the problem of determining the underground velocity parameters can be converted to a multi-output regression problem from seismic signals to velocity. The experiment generates seismic data by spontaneously generated seismic signals based on the seismic section data and treats them as input and output. Based on the CNN, the thesis proposes two algorithms called UnetRes1 and UnetRes2, which implements U-net with Residual Network and applies an end-to-end supervised learning to the synthetic seismic data and ground-truth velocity model, and the velocity model is established directly from the original seismic signal graph. In the training phase, the network establishes a nonlinear mapping from multi-seismic data to the corresponding velocity model. In the test phase, the training completed networks can be used to estimate the velocity model of new input seismic data.

This thesis concludes that the performance of UnetRes2 is better than UnetRes1 and U-net, and performance of UnetRes1 is much worse than UnetRes2. This is because that U-net can extract the features of pictures through the compression and expansion paths, skip connections, etc. and retain the information of original images. Adding residual learning to each convolutional layers can, to some extent, reduce training loss to avoid training degradation with the increase of the numbers of convolutional layers, and the more

numbers of convolutional layers that the input skips in the residual network, the better performance of the network is. Therefore, once a good generalized network is established, the calculation time of the seismic inversion can be greatly reduced.

Key words: speed inversion; seismic exploration; Deep Convolutional Neural Network; Residual Networks.

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 本课题的目的及研究意义	1
1.1.1 基于深度卷积网络的地震速度反演方法的特点及优势	1
1.1.2 传统的地震速度反演方法存在的劣势	1
1.1.3 目前针对劣势的解决措施及存在的问题	2
1.1.4 本文的目的及研究意义	2
1.2 国内外的研究现状	3
1.2.1 全波反演方法 (FWI)	3
1.2.2 机器学习方法 (ML)	3
1.2.3 深度学习方法 (DL)	4
1.3 研究内容	5
第 2 章 基于深度卷积网络的地震速度反演方法研究	6
2.1 重点解决的问题	6
2.2 深度卷积网络算法	6
2.2.1 基于 U-net 卷积网络	7
2.2.2 基于 V-net 卷积网络	8
2.2.3 残差网络学习	10
2.2.4 损失函数	11
2.2.5 子模型训练	11
2.3 UnetRes1 和 UnetRes2 算法	12
第 3 章 实验与结果分析	14
3.1 实验数据集	14
3.2 实验过程	16
3.2.1 训练阶段	16

3.2.2 测试阶段	16
3.3 评估指标	18
3.4 实验结果与分析	18
第 4 章 总结与未来工作	26
4.1 工作总结	26
4.2 未来工作	26
参考文献	28
致 谢	31
本科期间主要研究成果	32

第1章 绪论

本章介绍论文的研究背景以及研究意义,分析基于深度卷积网络的地震速度反演方法研究的现状及其不足之处,最后给出论文的主要工作和结构。

1.1 本课题的目的及研究意义

1.1.1 基于深度卷积网络的地震速度反演方法的特点及优势

地震层位是构造分析、反演、时空转换和地震属性分析的基础。地震波速度是地震层位中最重要的参数之一,精确的速度模型是地震成像技术的关键前提。然而,速度信息的获取一般采用人工交互或人工交互与传统的反演技术相结合的方法,这是一个耗时且容易出错的过程,且针对复杂地震反射特征的地震构造地形仍然存在许多挑战。针对这一问题,深度卷积神经网络(CNN)方法是深度学习领域中的一种典型的深度神经网络。与基于物理模型的传统反演方法不同,有监督的深度学习基于大数据训练,而不是先前的知识假设。地震层位的构造分析可以转化为地震信号到速度的多输出回归问题。CNN 可以充分利用网络结构的高度灵活性和分层特征提取的能力,在不连续性、横向变化和断层明显的地震体上进行有效的速度反演。

1.1.2 传统的地震速度反演方法存在的劣势

地震勘探方法除了在油气勘探开发中广泛使用外,在寻找地下水资源和民用工程建设中也发挥着重要作用。而地震波速度是地质勘探中最重要的参数之一,精确的速度模型是逆时偏移和其他高分辨率地震成像技术的关键前提。这样的速度信息传统上是通过层析成像^[1]或随机反演策略^[2],但这些方法耗时且计算昂贵,并且他们严重依赖人为的交互和质量控制。除此之外,通过使用地震数据的全波形信息,全波形反演(FWI)^[3]目前是重建高精度和高分辨率速度模型的最具吸引力的方法之一,但是由观测信号估计地震波速度是一个高度非线性的过程,传统的迭代法通常需要一个好的起始模型以避免陷入局部最小值。此外由于观测不充分或观测数据受到噪声污染,FWI 还面临着严重的非唯一性问题。

1.1.3 目前针对劣势的解决措施及存在的问题

分析和推断速度模型所使用的物理驱动计算技术是基于梯度的优化方法，其计算较为昂贵，并且通常在识别小结构时产生不令人满意的分辨率。近年来，随着计算能力的显著改善，机器学习和数据挖掘已经成功地从科学到工程的各个领域。与传统的优化解决方案不同，深度卷积网络共享卷积核，处理高维数据基本上无压力，可以自动的进行特征提取并且较为容易迁移。

但是，与物理驱动的传统方法相比，数据驱动方法的主要缺点是它们有不同程度的鲁棒性和泛化问题。深度卷积网络采用梯度下降算法很容易使训练结果收敛于局部最小值而非全局最小值，其池化层会丢失大量有价值信息，忽略局部与整体之间关联性，同时由于特征提取的封装，为网络性能的改进罩了一层黑盒。此外机器学习解决方案具有强大的数据依赖性，很多时候在特定数据集上训练得到的深度卷积网络模型在另一个数据集上执行效果远低于预期或者更糟。

1.1.4 本文的目的及研究意义

在油气勘探的各种地球物理方法中，目前使用最为广泛、解决油气勘探问题最有成效的是地震勘探方法。地震勘探通常用于根据地震波的传播来绘制地下层的结构。其基本原理是沿地面一条直线，在一个位置激发地震波，利用声波的反射或折射现象，其他位置用检波器能够接收经地下传播后的地震信号，利用这些信号可以确定地下的参数，如速度、密度、泊松比、孔隙度、地层压力、储层厚度等以及地震资料处理中的一些待求参数，根据观测数据与确定的地下参数推测地球内部的岩性与构造。由于地震勘探能够探测从大尺度到小尺度的目标特征，因此它在工程中寻找油气圈闭、解决油气勘探等问题以及地球地壳结构中发挥着重要作用。

目前，速度建模（VMB）贯穿于地震数据采集、处理、解释的全过程，是地震勘探中必不可少的一个环节。从表面地震波场精准重建地下图像需要精准了解记录位置和深度图像位置之间的局部传播速度。因此本论文主要为确定地下速度参数，原理上类似于医学 CT 成像。从计算机学科的角度，该问题可以看成是一个地震信号到速度的多输出回归问题，本论文利用卷积网络来解决这一回归问题。

本论文研究基于深度卷积网络对地震信号生成的速度数据到地震剖面数据进行端到端的有监督学习，直接从原始地震图建立速度模型。与基于物理模型的传统反演

方法不同，有监督的深度学习基于大数据训练，而不是先验的知识假设。在训练阶段，网络建立了一个从多点地震数据到相应速度模型的非线性映射。在预测阶段期间，经训练的网络可用于从新的输入地震数据估计速度模型。深度学习的一个关键特征是，他可以自动提取多层有用的特征，而不需要人工管理活动和初始速度设置。数据驱动的方法通常在训练阶段需要更多的时间，但是实际预测所需时间更少，预测更快，只需要几秒钟。因此，一旦建立了良好的深度卷积网络，地震反演的计算时间就可以大大减少。

1.2 国内外的研究现状

1.2.1 全波反演方法（FWI）

地震勘探通常需要人工能源，并在地表放着一系列接收器来记录地震波。处理记录数据的一个主要结果是重建地下速度模型，即地震速度反演，这对定位和成像目标体的精度有很大影响。地震全波形反转（FWI）技术通常用于地球物理勘探，以确定现场地质，地层和岩石质量。这些技术提供了有关地下分层和岩石地质力学属性的信息。

传统的 FWI 通过最小二乘意义上迭代最小化地震数据和合成数据之间的差异来重建速度模型^{[4][5]}。当提供适当精确的初始模型时，FWI 对于通过迭代更新获得速度结构是非常有效的。尽管这些传统方法在许多应用中显示出巨大的成功，但由于缺乏低频分量以及计算效率低、主观人为因素和其他原因，它们在某些情况下可能受到限制。因此，需要一种鲁棒的、有效和精确的速度估计方法来解决这些问题。

1.2.2 机器学习方法（ML）

机器学习（ML）是人工智能的一个领域，他使用统计技术来赋予计算机系统从大数据中“学习”的能力。近年来，大多数基于 ML 的方法主要集中于地震属性中的模式识别^[6]和测井中的相分类^[7]。Guillen 等人^[8]提出了一种基于地震属性的监督学习方法来检测盐体的新流程。使用 ML 算法来训练用于自动识别盐区的映射。他们得出结论，当选择的训练数据集具有足够的能力来描述复杂的决策边界时，ML 是一种很有前途的盐体分类机制。

1.2.3 深度学习方法 (DL)

随着深度学习 (DL) 的发展, Wang 等人^[9]通过使用全卷积神经网络 (FCN) 开发了一种从原始多点聚集中的盐检测技术。测试结果表明, 该方法与传统的偏移解释方法相比, 具有速度快、效率高的特点。Araya-Polo 等人^[10]使用基于深度神经网络 (DNN) 的统计模型, 直接从合成 2D 地震数据自动预测断层。在这一概念的启发下, Araya-Polo^[11]等人提出 VMB 方法, 该 DL 层析成像的一个关键要素是使用基于简化速度信息的相似性特征。在训练过程之前获得提取的特征, 并将其用作 DNN 输入来训练网络。Yang 等人^[12]提出了一种有监督的 DL 方法, 用于速度反演, 为传统的 FWI 公式提供了一种替代方案, 使用 FCN 来重建参数, 而不是执行关于地下参数的局部反演。此外, 大多数现有的方法不能充分利用地震数据, 并且可能引入偏差。针对这些不足, Li 等人^[13]分析了地震反演的内在特征, 并提出了一个端到端的 DNNS, 称为 SeisInvNet, 使得从每个增强的地震道都有助于重建整个速度模型。

地震反演需要从窄频带的地震数据得到宽频带的阻抗数据, 地震数据是 3D 数据, 传统的深度学习方法大多采用 1D 网络, 且需要对测井数据进行降采样以适应地震数据的时间采样率。这使得得到的模型往往只在测井周围有效, 在 3D 地震数据上的反演结果不一致。Di 等人^[14]提出一种半监督学习方法, 包含两个深度网络, 第一个对地震数据进行自学习, 获得地震数据的局部特征, 第二个网络结合第一个网络学习到的局部特征和 1D 的测井数据, 得到阻抗预测结果。

Sun 等人^{[15][16]}推论出在某些假设下, 循环神经网络 (RNN) 的训练过程可以等同于基于梯度的地震全波形反演 (FWI)。提出通过可训练的 RNN 建立一个波形反演模型。

Zhang 等人^[17]开发了一种基于实时数据驱动技术 VelocityGan, 以准确地重建地下速度。我们的 Velocitygan 建于生成式对抗网络 (GAN)^[18]上, 并且从原始地震波形数据到速度图像进行端到端的学习映射函数。与其他基于编码器的数据驱动的地震波形反转方法不同, VelocityGaN 从数据学习正则化, 进一步将正则化施加到生成模型, 从而改善了反转精度。Zhang 等人进一步开发了基于 VelocityGan 的转移学习策略以减轻泛化问题。在合成地震反射数据上进行了一系列实验, 以评估 VelocityaN 的有效性, 效率和泛化。Zhang 等人不仅将其与现有的物理驱动的方法和 DataDRiven

框架进行比较，而且还进行了多个转移学习实验。实验结果表明，VelocityGaN 实现了基线之间的最先进的性能，可以在一定程度上提高泛化结果。

1.3 研究内容

文章具体的主要研究内容包括：

本文主要由四章构成。第一章为绪论，介绍了本文的研究背景，给出了本文的研究目的和研究意义，分析国内外的关于地震速度反演方法的研究现状，并且叙述论文的主要研究内容。第二章为本文实验使用的核心算法，包括了 U-net 深度卷积网络、V-net 深度卷积网络、残差网络学习以及本论文提出的 UnetRes1 和 UnetRes2 算法。第三章介绍了实验使用到的数据集、实验的训练和测试阶段以及实验的结果对比与分析。第四章总结了本论文完成的任务，并且对未来工作进行了叙述。

第 2 章 基于深度卷积网络的地震速度反演方法研究

本章本章先给出本文重点解决的问题，详细叙述两种深度卷积网络的结构和原理，其中包括 U-net 和 V-net，然后介绍 V-net 中使用到的残差网络学习，最后给出本论文提出的两种深度卷积网络算法 UnetRes1 和 UnetRes2。

2.1 重点解决的问题

为了从原始地震数据中自动实现地震速度模型，本论文修改了 U-net 网络^[19]，原始网络是为了解决生物图像分割问题，在地震数据中，通过在不同的震源位置生成炮集，共同合并为同一个模型一起送入网络，以提高数据冗余度。此外，原始 U-net 的输入和输出是相同维度，但在地震速度反演问题中，本论文期望从多通道的地震数据转化为预测单维度的速度模型，这样做使得神经网络能够在收缩和扩张过程中自我训练，将地震数据直接映射到精准的速度模型。本论文同时结合了 V-net 网络^[20]中运用残差网络学习的特点，去进一步修改 U-net 网络，提出 UnetRes1 和 UnetRes2 两种算法，进而减小损失值，优化训练效率以达到更好的预测效果。

2.2 深度卷积网络算法

卷积神经网络是目前深度学习算法中应用最广最成功的领域之一。一般的，卷积神经网络由卷积层、池化层和全连接层三种不同结构组成。卷积层的作用是特征提取，越是处在网络前端的卷积层，提取的越是低级的特征，后端的卷积层则会将前端卷积层提取的低级特征再次组合提取成高级特征，正是这种特性，使得我们可以直接对卷积神经网络输入图像类数据，而不用进行额外的人工特征图提取操作。池化层是为了防止卷积操作导致计算机内存溢出，它实际上是一种下采样处理，有最大池化和平均池化两种。池化操作能有效降低网络体积，减少计算量，提高计算效率。全连接层则将提取到的特征进行重新排列。

卷积神经网络其参数共享机制可以使网络的参数数量大大减少，而且可以有效地避免过拟合。此外由于连接的稀疏性可以得出输出图像的任意单元之和输入图像的一

部分有关系，而在传统神经网络中，由于都是全连接导师输出的任意单元都要收到输入的所有单元的影响。

2.2.1 基于 U-net 卷积网络

U-net 是以 FCN 全卷积神经网络为基础设计的，其中包含两条串联的路径压缩路径和扩展路径，如图 2-1 所示。

压缩路径用来提取图像特征，捕捉内容，扩展路径用来精准定位，将提取的特征解码为与原始图像尺寸一样的分割后的预测图像。与 FCN 不同的是，在上采样过程中保留了大量的特征通道，从而使更多的信息能流入最终复原的分割图像中。另外，为了降低在压缩路径上损失的图像信息，还将压缩路径和扩展路径同尺寸的特征图进行叠加，收集在压缩路径中会丢失的细粒度细节信息，提高网络的分割精度，再进行卷积和上采样工作，以此整合更多信息进行图像分割。在训练阶段，网络建立了一个从多点地震数据到相应速度模型的非线性映射。在预测阶段期间，经训练的网络可用于从新的输入地震数据估计速度模型。

U-Net 和 FCN 非常的相似，其网络架构都使用了编码和解码（encoder-decoder）结构^[21]。和 FCN 相比，U-Net 的第一个特点是完全对称，而 FCN 的解码器相对简单，只用了一个反卷积的操作，之后并没有跟上其他卷积结构。第二个区别就是越级连接（skip connection），与 FCN 不同的是 U-net 越级层融合方式采用的是叠操作（concatenation），是对其通道数进行拼接，使特征图变厚，FCN 采取的是加操作（summation）。此外 U-Net 的越级层融合次数增加，FCN 只在最后一层进行了融合，U-net 有 4 次融合，实现了多尺度的特征融合，充分的利用了上下文（context）信息，一定解决了感受野大小与分割精度之间的矛盾。

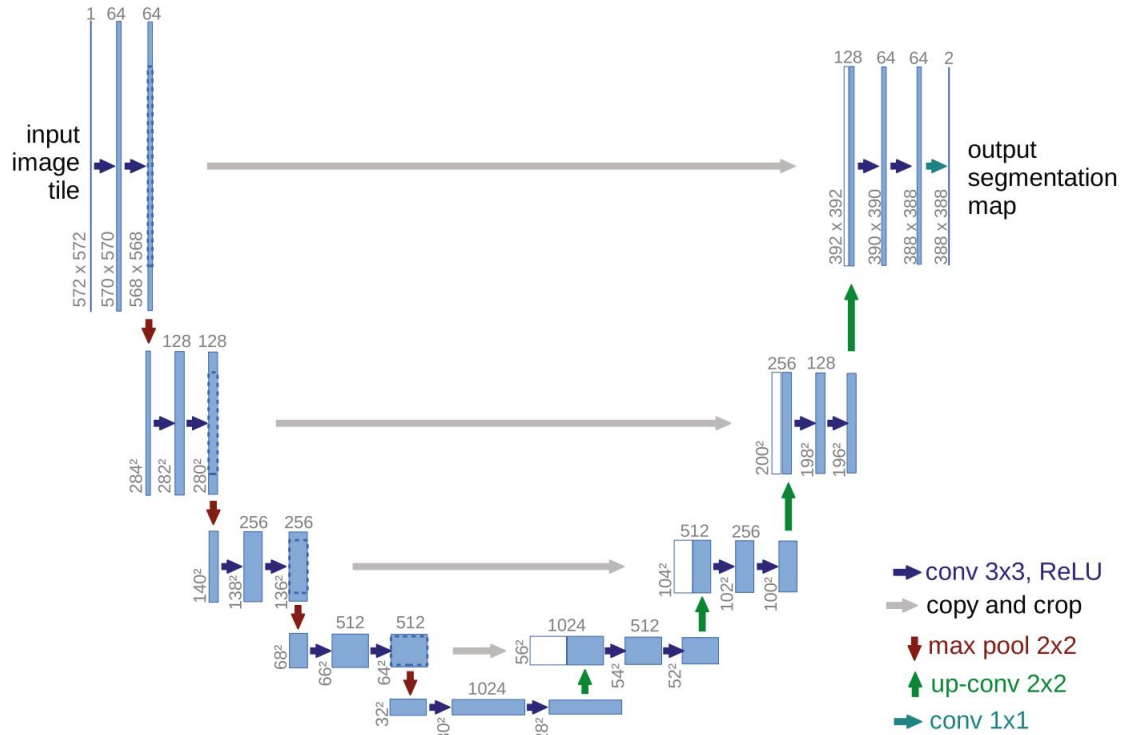


图 2-1 U-net 架构

2.2.2 基于 V-net 卷积网络

V-net 和 U-net 有异曲同工之处。V-net 是一种基于三维全卷积神经网络的三维图像分割方法，网络结构如图 2-2 所示。V-net 同样也是使用卷积操作来提取数据的特征，于此同时在每个“阶段”的末尾通过合适的步长来降低数据的分辨率。整个结构的左边是一个逐渐压缩的路径，而右边是一个逐渐解压缩的路径。最终输出的大小是和图像原始尺寸一样大的。所有的卷积操作都使用了合适的填白操作。

左边的压缩路径和右边的扩展路径均被分为了多个阶段，每个阶段都具有相同的分辨率且依次递增的包含 1 到 3 个卷积层。为了使每个阶段学习一个参数函数，将每阶段的输入和输出进行相加以获得残差函数的学习。结合试验观察得知：这种结构为了确保在短时间内收敛需要一个未曾学过残差函数的相似性网络。

每个阶段的卷积操作使用的卷积核大小为 $5 \times 5 \times 5$ 。在压缩路径一端，数据经过每个阶段处理之后会通过大小为 $2 \times 2 \times 2$ 且步长为 2 的卷积核对分辨率进行压缩。因此，每个阶段结束之后，特征图大小减半，这与池化层具有相同的效果。因为图像分辨率降低和残差网络的形式，从而将特征图的通道数进行的翻倍。

V-net 使用卷积操作替代池化操作，在一些特殊的实现方式下可以在训练过程中减小内存的使用。这是因为在方向传播过程中并不需要像池化操作一样去切换输入和输出之间的映射，同时也更易于理解和分析。此外，下采样有利于在接下来的网络层中减小输入信号的尺寸同时扩大特征的感受野范围。

V-net 网络右边部分的功能主要是提取特征和扩展低分辨率的空间支持以组合必要的信息，从而输出一个两通道的体数据分割。这最后一个卷积层使用的卷积核大小是 $1 \times 1 \times 1$ ，输出的大小与原输入大小一致。两个特征图通过这个卷积层来利用归一化指数函数（softmax）来生成前景和背景的分割概率图。在右边解压缩路径中每个阶段的最后，通过一个解卷积操作来恢复输入数据的大小。于此同时，在收缩路径中每阶段的结果都会作为输入的一部分加入到右边解压缩对应的阶段中。这样就能够保留一部分由于压缩而丢失的信息，从而提高最终边界分割的准确性。同时这样有利于提高模型的收敛速度。

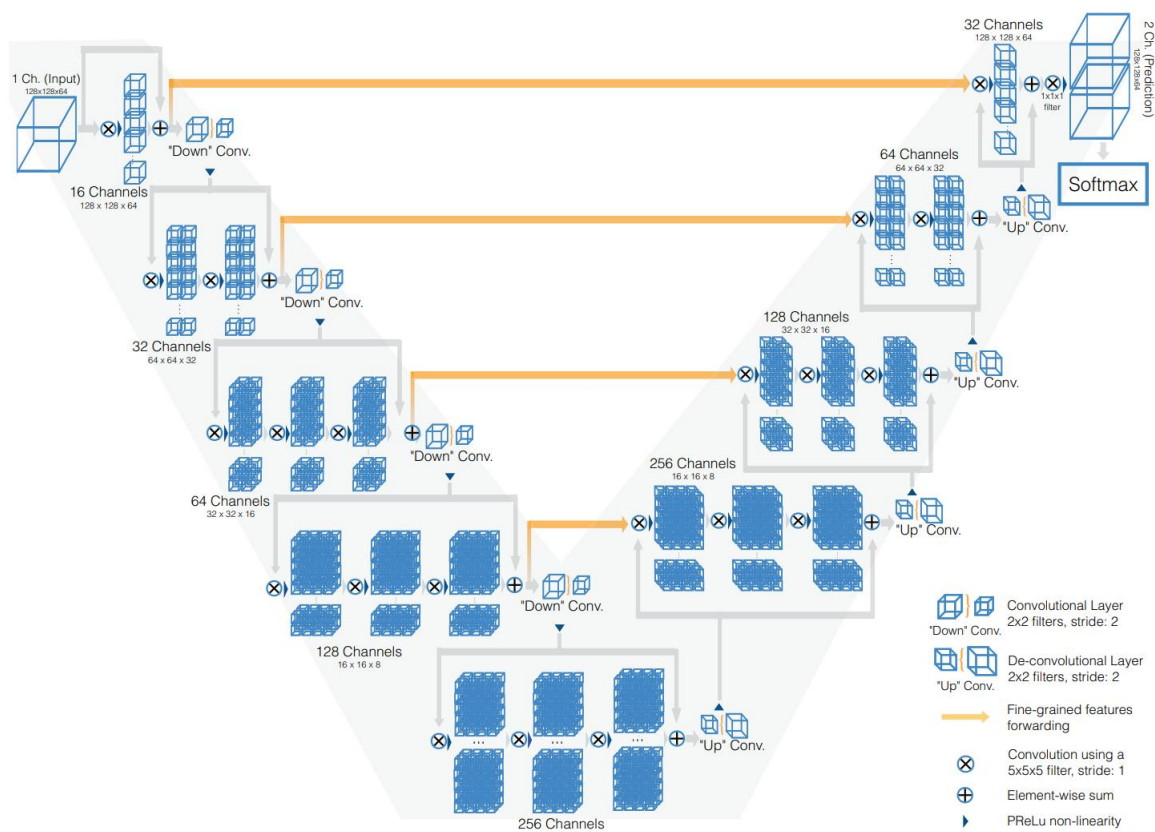


图 2-2 V-net 架构

2.2.3 残差网络学习

残差网络是由残差块构建的，如图 2-3 所示。




图 2-3 残差块结构

如图是一个两层神经网络在 i 层激活，根据等式 $a^{i+1} = g(w^{i+1} \times a^i + b^{i+1})$ ，然后通过非线性 Relu 激活函数 g 得到 a^{i+1} 。此时我们将 a^i 直接传递到两层神经网络后，在第二次激活前加上输入 a^i ，得到 $a^{i+2} = g(w^{i+2} \times a^{i+1} + b^{i+2} + a^i)$ 。

如果将深层网络的后面若干层学习成恒等映射 $H(x) = x$ ，那么模型就退化成浅层网络，但是直接去学习这个恒等映射是很困难的，于是就假设当输入为 x 的时候，学习到的特征为 $H(x)$ ，定义 $F(x) = H(x) - x$ 为残差，下一层的输入就为 $F(x) + x$ ，把问题转化为学习一个残差函数。如果残差是 0，下一层的输入就是 x ，相当于做了一个恒等映射，一定程度上解决了网络退化的问题。

在 CNN 网络中，整个网络就是一个信息提取的过程，从底层的特征逐渐抽取到高度抽象的特征，网络的层数越多也就意味这能够提取到的不同级别的抽象特征更加丰富，并且越深的网络提取的特征越抽象，就越具有语义信息。对于传统的 CNN 网络，简单的增加网络的深度，容易导致梯度消失和爆炸。针对梯度消失和爆炸的解决方法一般是正则初始化和中间的正则化层，但是这会导致退化问题，随着网络层数的增加，在训练集上的准确率却饱和甚至会下降。实际上，如果没有残差网络，对于一个普通网络来说，深度越深意味着用优化算法越难训练。

因此，为了即可以保留深层网络的深度，又可以有浅层网络的优势去避免退化问题，我们可以直接将浅层网络的输入信息直接传达到神经网络的深层，不再沿着主路径传递，相当于走了一个捷径。深度残差网络的旁路支线可以将输入直接连接到后面层，使得后面层可以直接学习残差。传统的卷积层或全连接层在信息传递时，会存在

或多或少的信息丢失、损耗等问题。残差网络在某种程度上解决了这个问题，通过直接将输入信息绕道传到输出，保护信息的完整性，于是，整个网络则只需要学习输入、输出差别的那一部分，简化学习目标和难度，提高学习的效率和准确性。

2.2.4 损失函数

本文实验中使用的损失函数为均方误差损失函数(Mean Square Error, 简称 MSE), 即所有样本误差的平方和, 如公式 2-1 所示, 其中 m 为样本个数, \hat{y} 为预测值, y 为真实值。

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$

公式 2-1

2.2.5 子模型训练

在计算完样本的损失函数之后, 通过求偏导数的方式计算得出模型中每个参数的梯度, 再使用优化器更新模型的参数即可进行训练。本文的实验中, 使用的是 Adam^[22] 优化器。

Adam 优化器是传统梯度下降法 (SGD) 的变形, 能基于训练数据迭代式地更新模型的参数。参数迭代更新如公式 2-2 所示, 其中 δ 是正步长, $g(1/mh \nabla_{\Theta} L_h(d_n; \Theta; v_n))$ 表示函数。随机梯度下降保持单一的学习率更新所有的参数, 学习率在训练过程中并不会改变, 与传统的随机梯度下降法不同, Adam 通过计算梯度的一阶矩估计和二阶矩估计而为不同的参数设计独立的自适应性学习率, 具有学习稳定和受噪声影响小等优点。在数据和参数方面, 该算法实现简单, 计算上高效并且适用于解决规模大的问题。

$$\Theta_{t+1} = \Theta_t - \delta g\left(\frac{1}{mh} \nabla_{\Theta} L_h(d_n; \Theta; v_n)\right)$$

公式 2-2

2.3 UnetRes1 和 UnetRes2 算法

本论文提出的深度卷积网络同样由一个收缩路径和扩展路径构成。

收缩路径遵循卷积网络的典型架构，一共通过五步，其中每一步都首先经过两个或三个重复单元：3×3 的卷积层、批标准化处理和 ReLU 激活函数，其中每一个重复单元中都应用了残差学习网络，输入端跳转的卷积层数分别为 1 或 2。然后通过一个 2×2、步长为 2 的最大池化层进行下采样。每一步的卷积核个数从浅到深分别为：64、128、256、512 和 1024 个。



由于每次卷积中都会丢失边界像素，为保证每个卷积层的输出与输入图像尺寸一致，网络中的卷积全部使用了适当的填白（padding），进行尺寸控制。

扩展路径和收缩路径成对称结构，同样一共通过四步，每一步的卷积核个数从深到浅分别为 512、256、128 和 64 个。其每一步都首先使用 2×2 的反卷积，每次使用反卷积都将特征通道数量减半，特征图大小加倍。反卷积过后，将反卷积的结果与收缩路径中对应步骤的特征图拼接起来，跟随两个或三个重复单元：3×3 卷积层、批标准化处理和 ReLU 激活函数，并且每层卷积和收缩路径一样加入了残差网络学习。

在最后一层的最后一个卷积操作完成后进行图像大小剪裁，使其和目标输出图像尺寸一致，然后使用一个 1×1 的卷积层将 64 个通道的特征向量映射成一维的输出图像。

该网络总共有四个 2×2、步数为 2 的最大池化层，32 个卷积层：27 个 3×3、步数为 1 的顺序卷积层、4 个收缩到扩展的卷积层和 1 个 1×1 的卷积层。

没有加入残差学习，每步有两个卷积层的原始的 U 网络算法本文称为 U-net，输入端跳转的卷积层数为 1，每步有两个卷积层的称为 UnetRes1，如图 3-3 所示，输入端跳转的卷积层数为 2，每步有三个卷积层的称为 UnetRes2，如图 3-4 所示。



第3章 实验与结果分析

本章介绍了在实验中使用的数据集、实验的实施过程、对预测结果如何评估以及实验结果展示。

3.1 实验数据集

为了训练有效的网络，需要合适的大规模训练集，即输入输出对。

在本论文中，输入端数据集获得方式是基于地震勘探方法，如图 3-1 所示。其基本原理是沿地面一条直线，在一个位置激发地震波，利用声波的反射或折射现象，其他位置用检波器能够接收经地下传播后的地震信号，利用这些信号可以确定地下的参数，如速度以及地震资料处理中的一些待求参数，根据观测数据与确定的地下参数推测地球内部的岩性与构造。

训练数据集包含 1600 个输入输出对，输出端是真实地震剖面图，如图 3-2 所示，详细显示了在不同地下构造层中地震波传播速度的不同。输入端是地震数据，如图 3-3 所示，对于每个速度模型，均匀放置 5 个震源，并依此模拟炮集，如图 3-4 所示，箭头为可控震源位置，其向下发射地震波，由于在不同地质层面上传播的速度不同，因此可以通过速度建模去模拟地下构造。此外，301 个接收器以相同的空间间隔均匀放置用来构成几何结构。在原始地震剖面图的基础上通过波动方程生成速度模型作为输入数据。

由于使用了端到端的有监督学习方法，测试数据集的地面真实速度模型与训练数据集具有相似的地质结构。且用于预测的所有速度模型不包括在训练数据集中，并且在预测过程中是未知的。用于预测的输入地震数据也通过使用与用于生成训练数据集的输入数据相同的方法来获得。测试数据集一共为 100 个样本。

输入数据维度为 $2001 \times 301 \times 5$ ，输出数据维度为 $201 \times 301 \times 1$ 。




图 3-1 地震勘探方法示意图

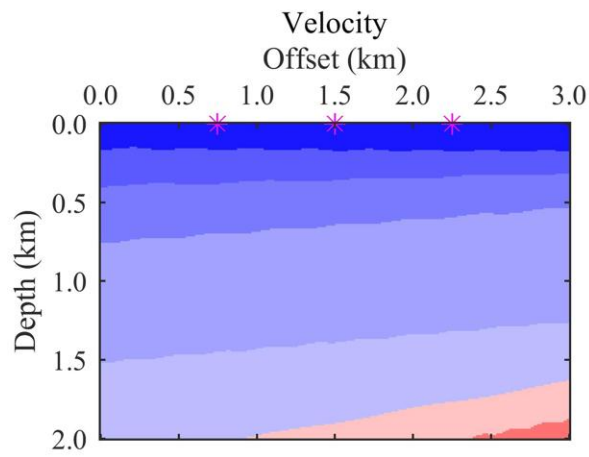


图 3-2 地面真实速度模型




图 3-3 地震数据（3 炮为例）




图 3-4 可控震源位置示意图

3.2 实验过程

划分完数据集之后，就加入了网络的构建和网络的训练以及测试阶段。首先构建深度卷积网络，接着将训练数据以分批的方式输入到模型中，通过正向传播得出预测值，并通过预测值与真实值之间的差距计算出损失函数值，然后通过反向传播计算出网络中每个参数的梯度，最后通过优化器进行参数更新。当整个训练数据集向前和向后通过神经网络一次时，称为一次迭代，本实验一共迭代 100 次。每一次迭代中都将所有训练数据随机打乱然后以批次顺序进行训练和传播，每 20 个训练集为一个最小批次训练，每 20 次迭代保存一个模型。训练完成后，就使用训练保存的模型在测试集上进行测试。本文的实验使用 python 语言实现，训练深度卷积网络模型的服务器配置如表 3-1 所示。

表 3-1 训练模型的服务器配置参数

镜像	Python 3.8	PyTorch 1.10.0	Cuda 11.3	
GPU	24GB 显存	显卡 RTX 3090 × 1		
CPU	45GB 内存	Intel(R) Xeon(R) Gold 6330 CPU	14 核	2.00GHz

3.2.1 训练阶段

训练阶段开始前先进行数据处理工作，将 3200 个输入图像和输出图像经过处理生成卷积网络的训练集。

首先分别对训练集的输入图像和输出图像进行不同程度的下采样操作降低维度，然后，因为训练集中输入端每个数据是 5 通道的图像，需要先进行扁平化操作变成单通道的向量。最后将两端所有数据分别合并成两个单独的向量，用来后续的训练。

训练阶段开始需要选择合适的 GPU 和建立好的卷积网络模型，设置优化器，初始化损失值并且载入训练集数据。对于每次迭代，都依次将数据集先转化为张量类型再进行分批训练，向前传播过程清空上一次迭代的梯度值并且计算损失函数值，然后开始反向传播，通过优化器减小损失函数值来学习每层卷积网络的参数，进而优化网络模型。一共迭代 100 次，每 20 次迭代保存一个模型，同时生成所有迭代的损失函数图像。

训练阶段参数如表 3-2 所示。

表 3-2 训练阶段参数

训练集大小		1600
学习率		0.001
批次大小		10
迭代次数		100
下采样维度	输入数据	(5,1)
	输出数据	(1,1)

3.2.2 测试阶段

测试阶段前的数据加载工作和训练阶段一致，所有初始化完成以后需要载入训练好的模型，通过神经网络参数计算得到预测结果。在训练结束后，保存每个测试集的损失函数值、峰值信噪比和结构相似性值，生成原始图像和预测图像的对比结果图。

测试阶段参数如表 3-3 所示。

表 3-3 测试阶段参数

测试集大小	100
批次大小	10

3.3 评估指标

在模型训练完毕之后，需要采用全局的评估指标来评估模型预测的准确程度。本文的实验中使用了两种模型评估指标来反映预测模型的准确率。

第一种评估指标为峰值信噪比（PSNR），峰值信噪比是常用的衡量信号失真的指标。该参数是基于图像像素灰度值进行统计分析，但是由于人类视觉特性的差异性，通常出现的评价结果与人的主管感觉不一致，但其仍然是一个有参考价值的评价指标。PSNR 的值越大，图像质量越好。

第二种评估指标为结构相似性（SSIM），结构相似性是高度结构化的自然影像，从亮度、对比度、结构三方面评价图像质量，故邻域像素具有较强的关联性，即物体结构信息的相似性，对比峰值信噪比更复合人类视觉观察到的直观效果，其具有对称性、上下界等性质。SSIM 的取值范围为 0 到 1，值越大越好。

3.4 实验结果与分析

本节对于三种卷积神经网络在测试集上的预测结果进行展示，测试数据一共 100 个样本，本章实验展示 40 张结果，如图 3-5 到图 3-9 所示。每一列从左到右依次是地震速度模型的真实数据、U-net 预测结果、UnetRes1 预测结果和 UnetRes2 预测结果。

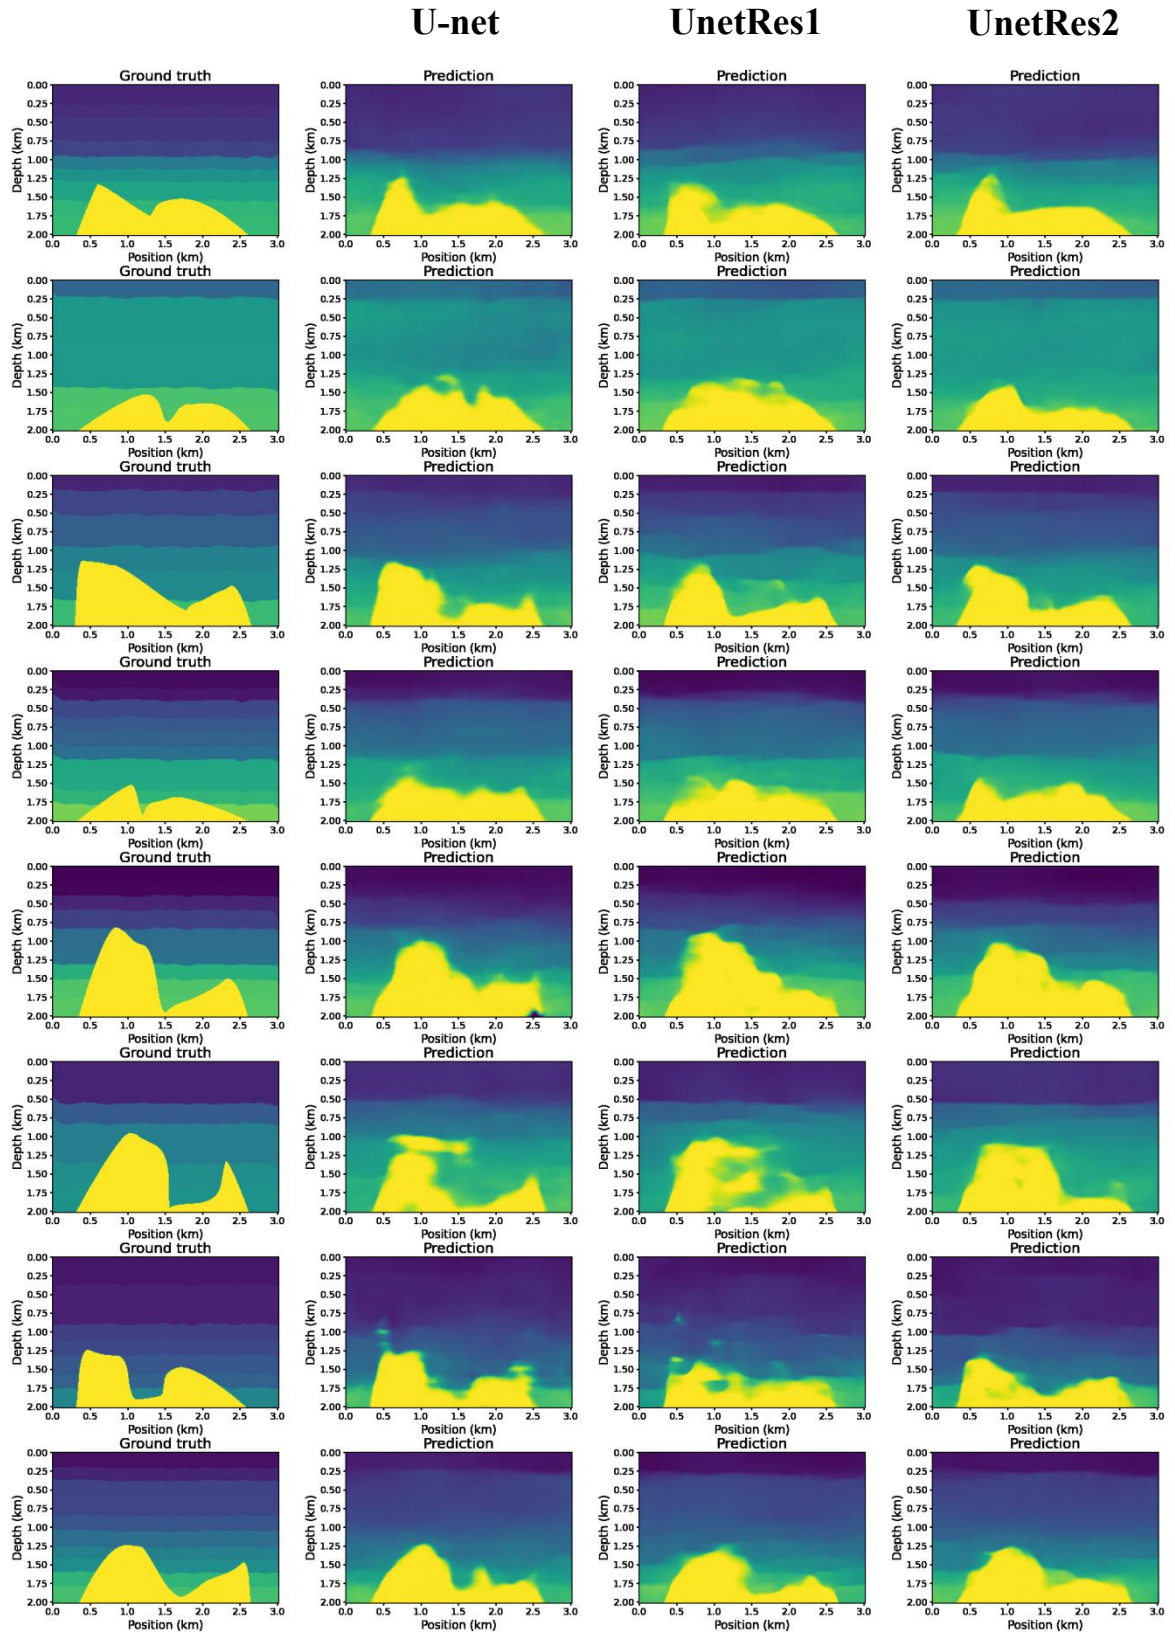


图 3-5 预测速度模型（1-8）

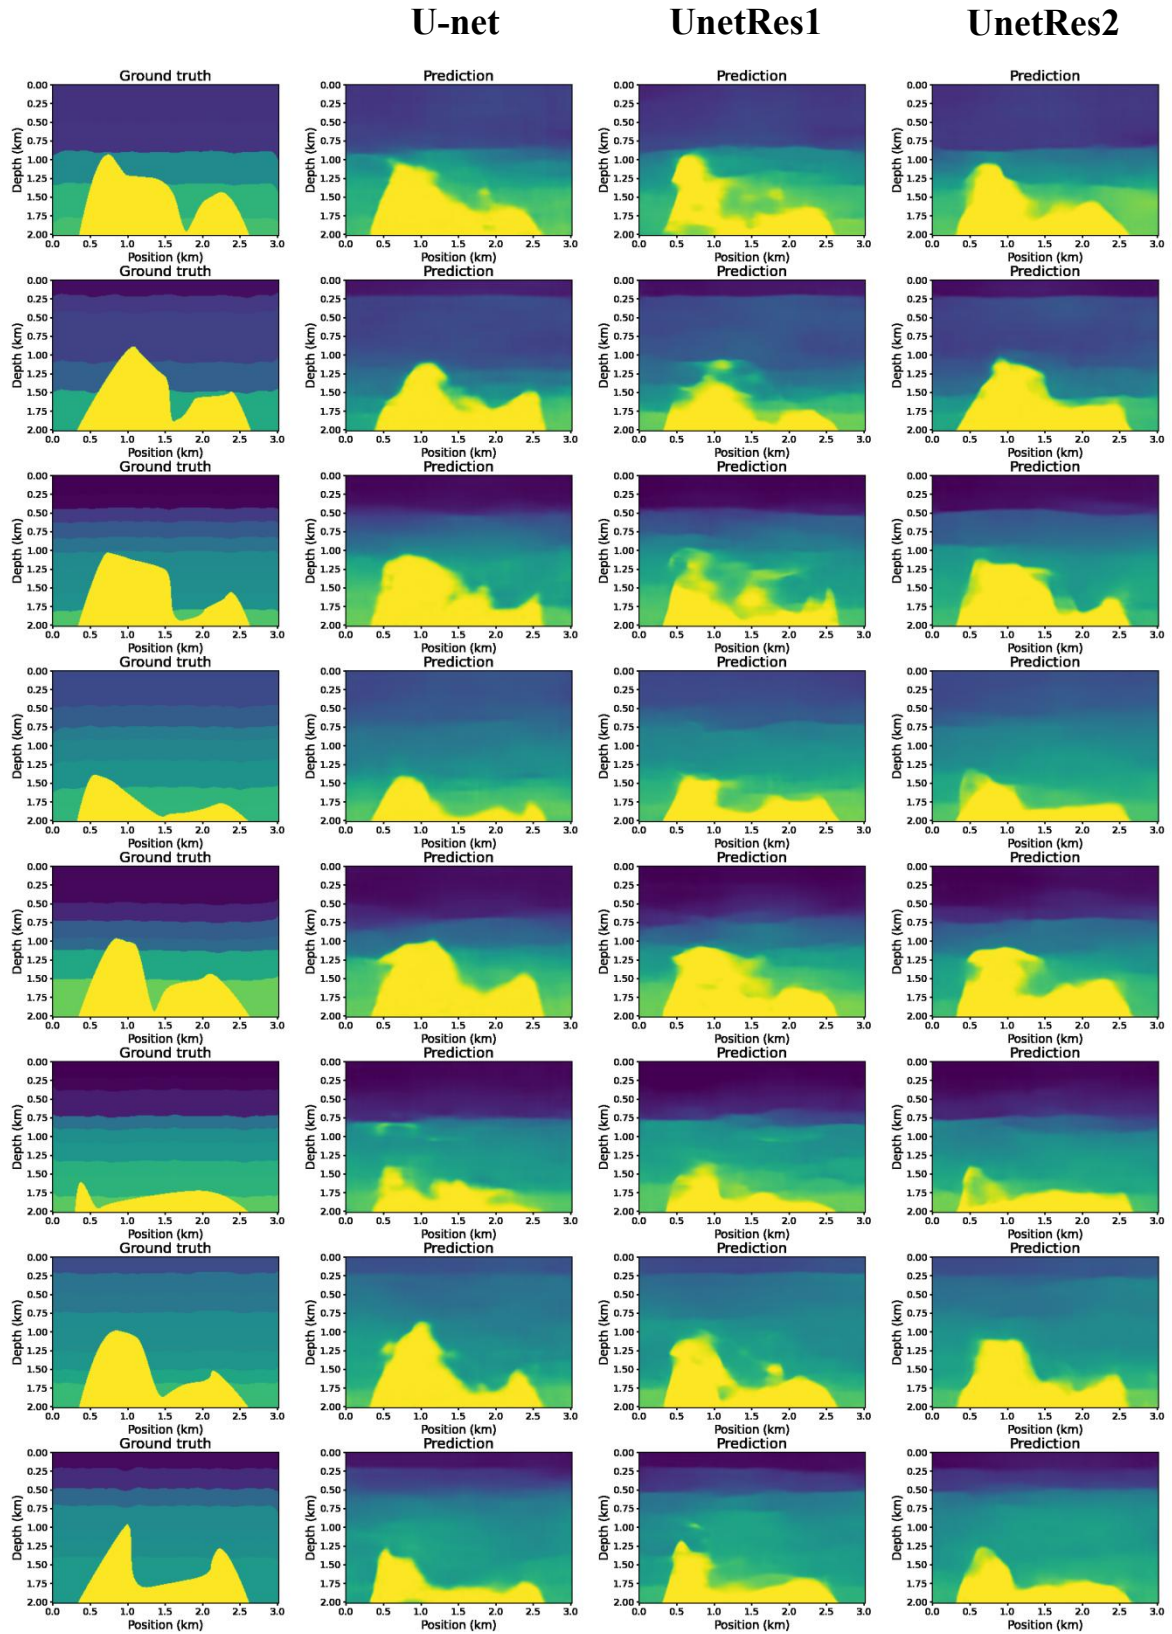


图 3-6 预测速度模型（9-16）

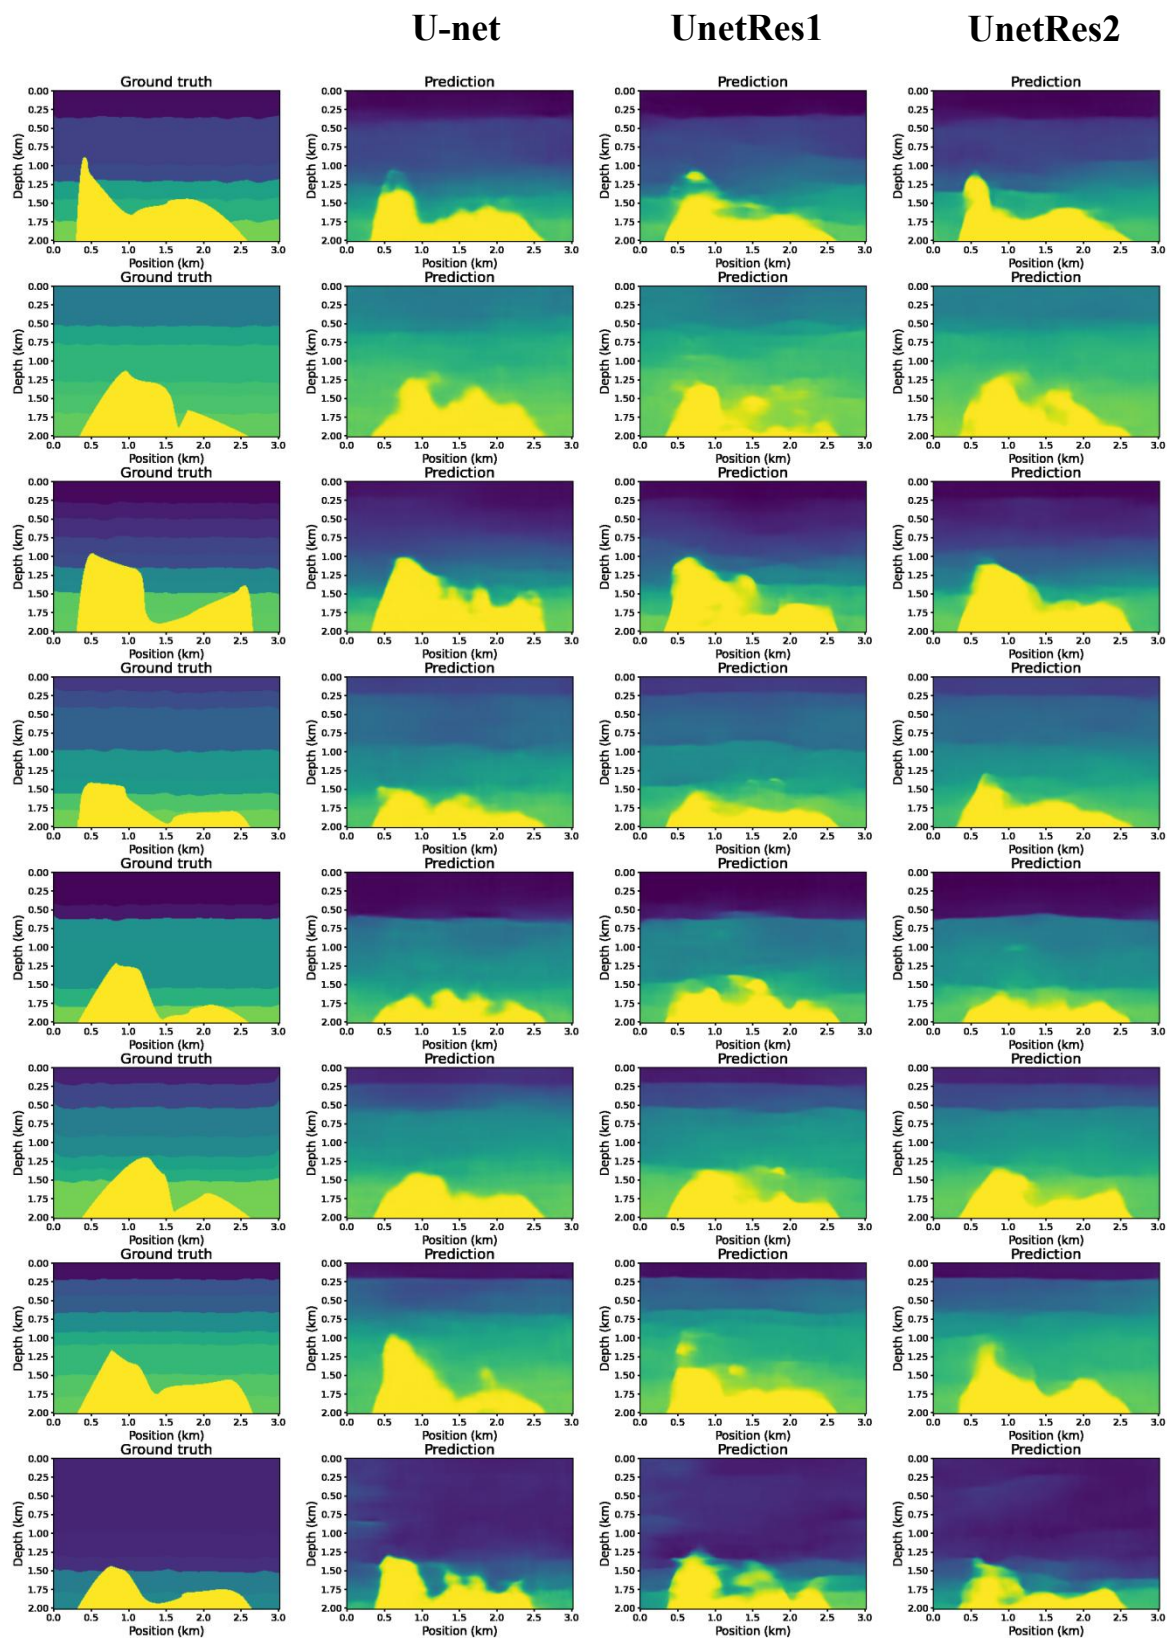


图 3-7 预测速度模型（17-24）

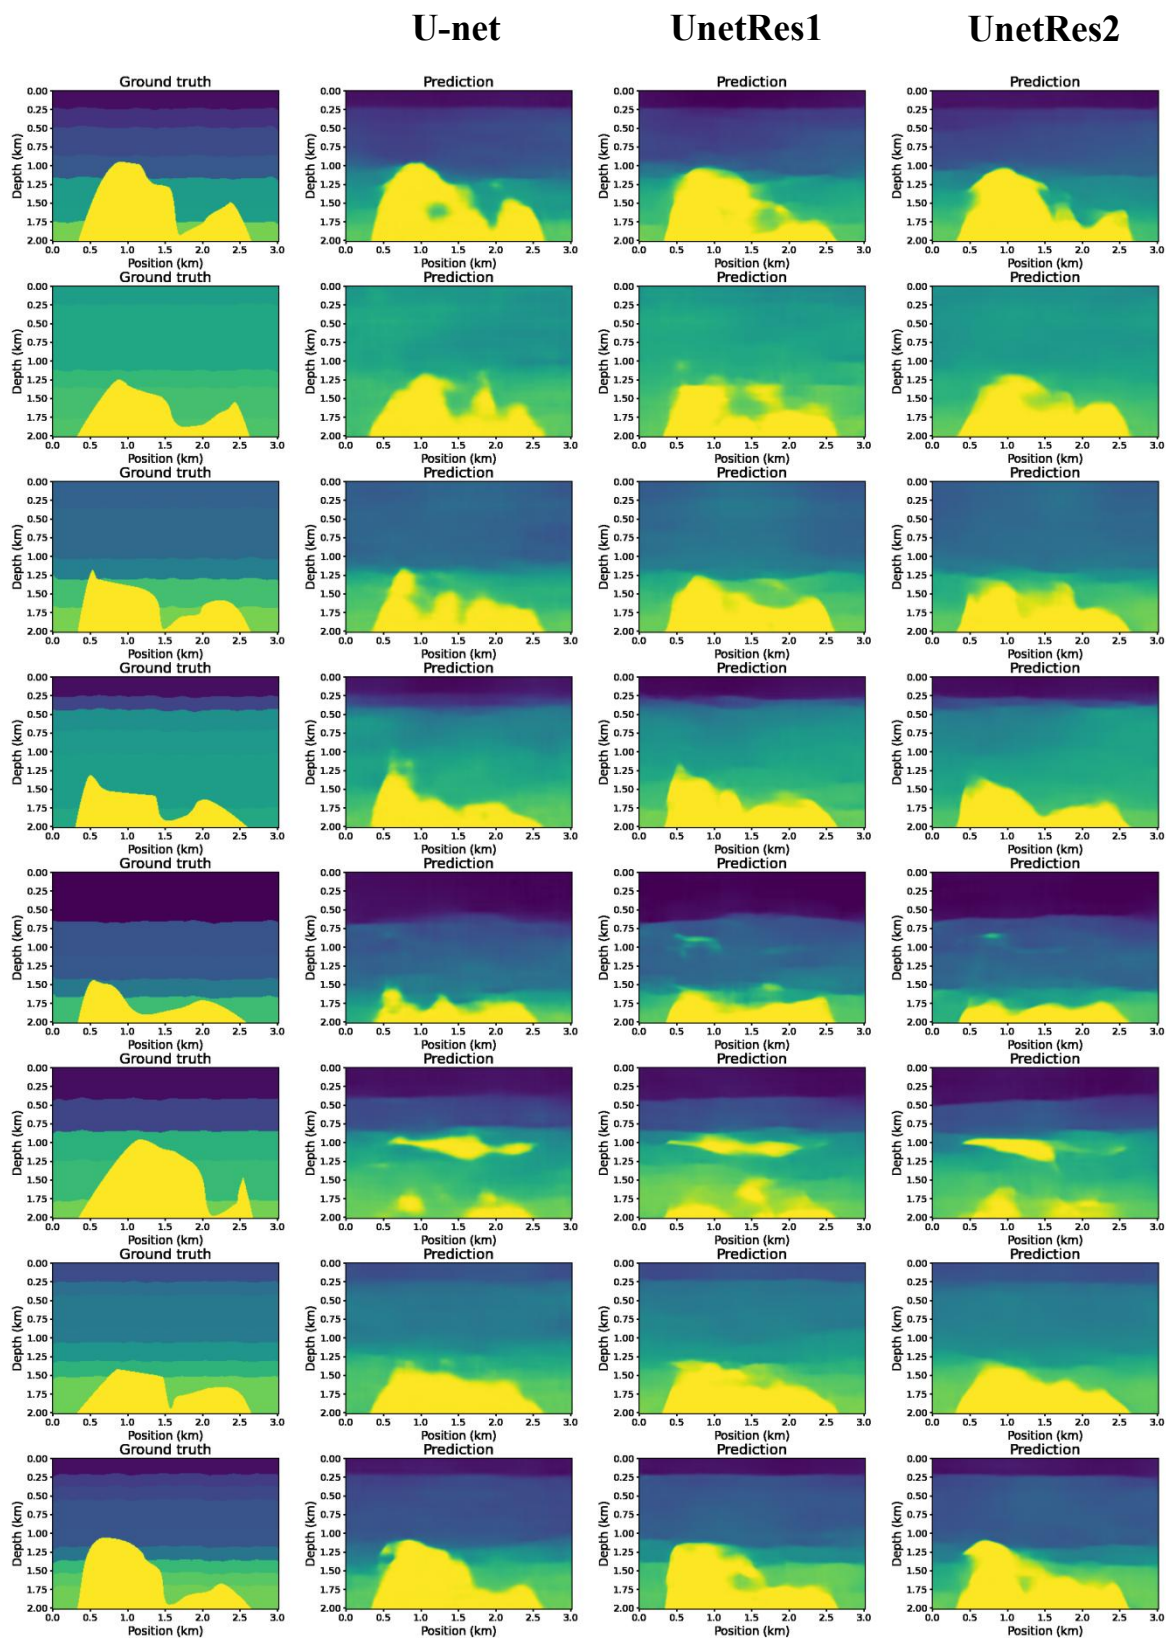


图 3-8 预测速度模型（25-32）

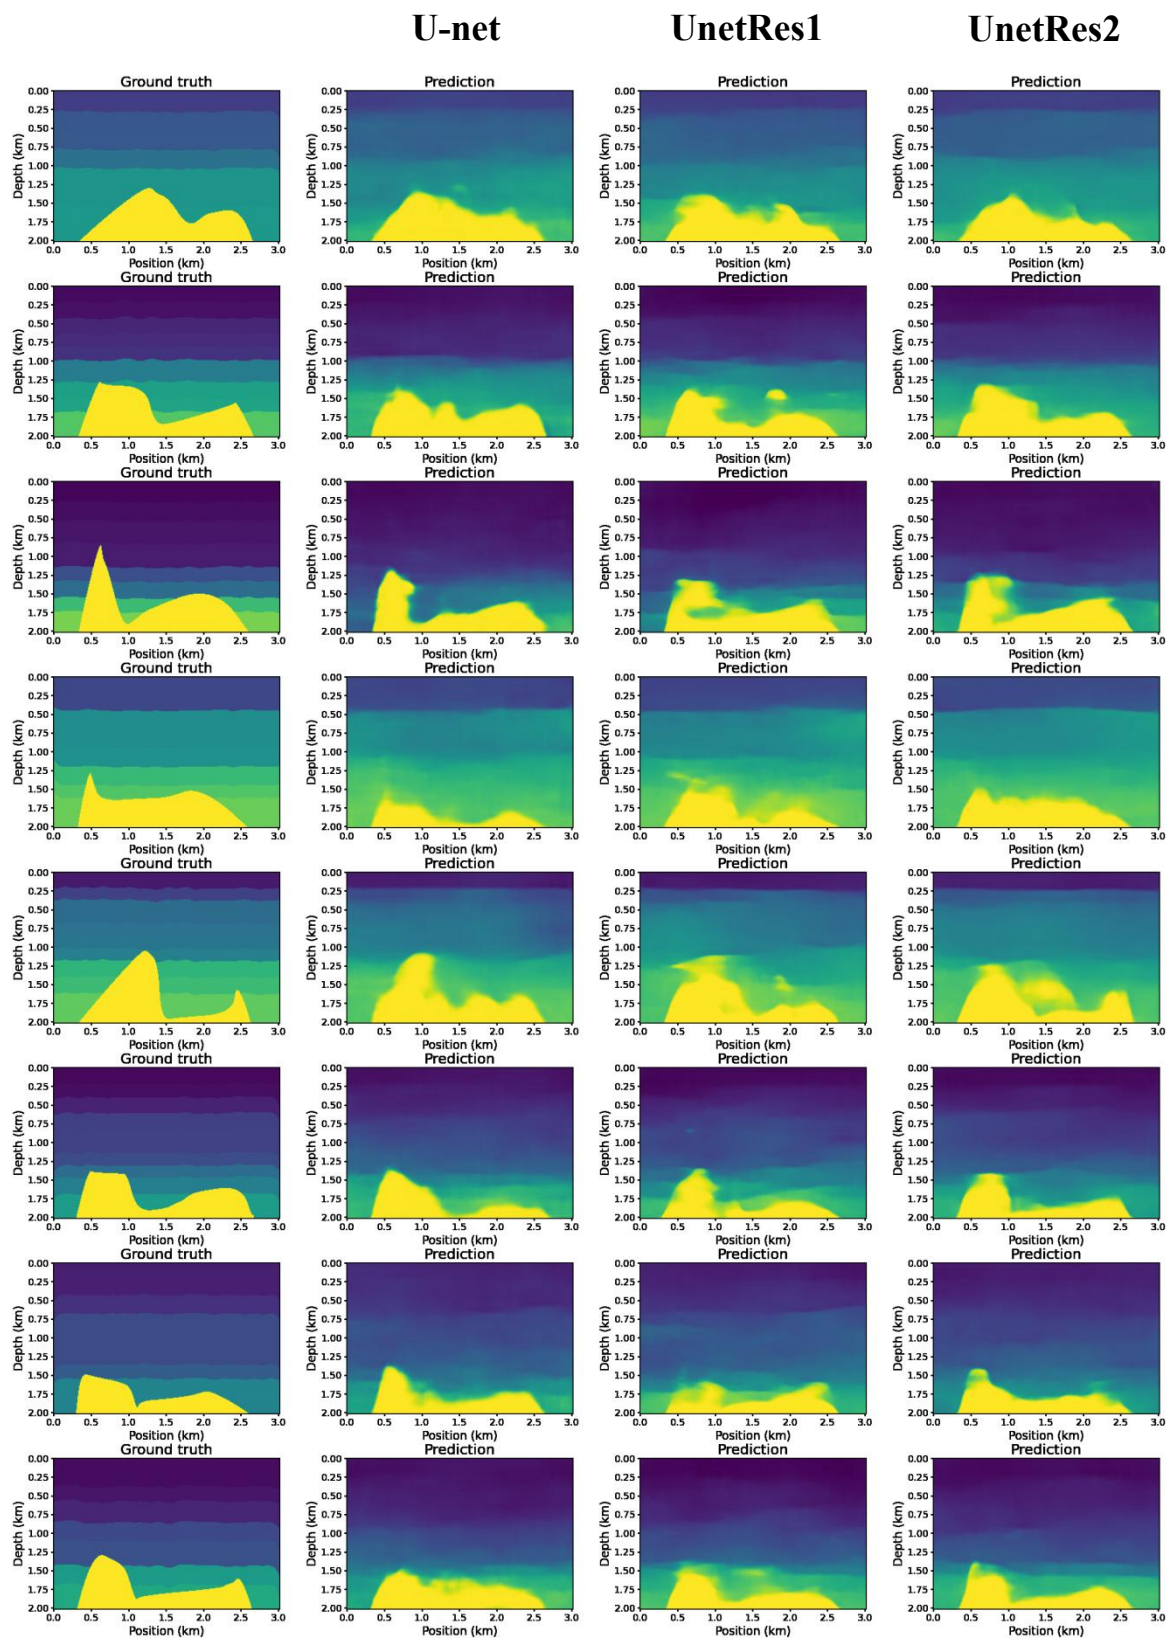


图 3-9 预测速度模型（33-40）

本论文分别对三种卷积网络在训练阶段多次迭代后得到的损失函数值进行可视化展示，如图 3-10 所示。可以看出加入了残差网络学习后，训练的损失函数值有明显下降。三个算法的 loss 曲线放在同一张图的效果如图 3-11 所示，UnetRes1 和 UnetRes2 几乎重合。




图 3-10 训练损失函数图像（从左到右分别为 U-net，UnetRes1，UnetRes2）

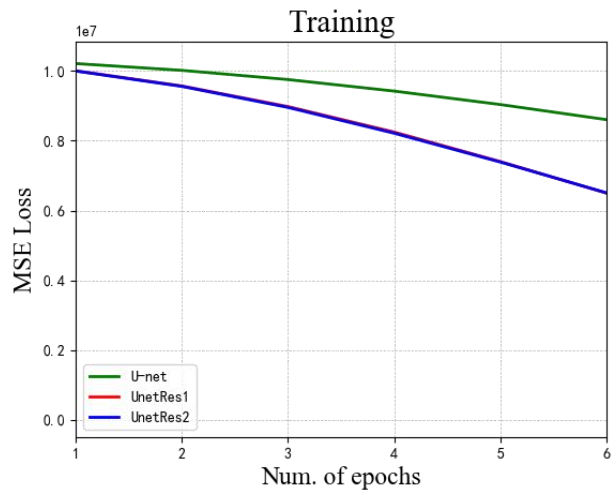


图 3-11 训练损失函数图像

本论文分别对三种卷积网络得到的预测图像的质量进行评估，分别计算出 100 个测试样本的峰值信噪比和结构相似性的均值和均方差，如表 3-4 所示。

表 3-4 评估指标

算法	变量	均值
U-net	PSNR	22.4570 ± 2.4688
	SSIM	0.9031 ± 0.0173
UnetRes1	PSNR	22.0350 ± 2.4954
	SSIM	0.9006 ± 0.0169
UnetRes2	PSNR	22.8786 ± 2.4819
	SSIM	0.9062 ± 0.0163

此外，本论文分别通过柱状图对三种卷积网络的峰值信噪比和结构相似性的均值进行评估，如图 3-12 和 3-13 所示。可见 UnetRes2 的效果要比 UnetRes1 和 U-net 更好，而 UnetRes1 远不如 U-net。说明残差学习的准确率提升度随着输入端跳转的卷积层个数增加。




图 3-12 PSNR 柱状图

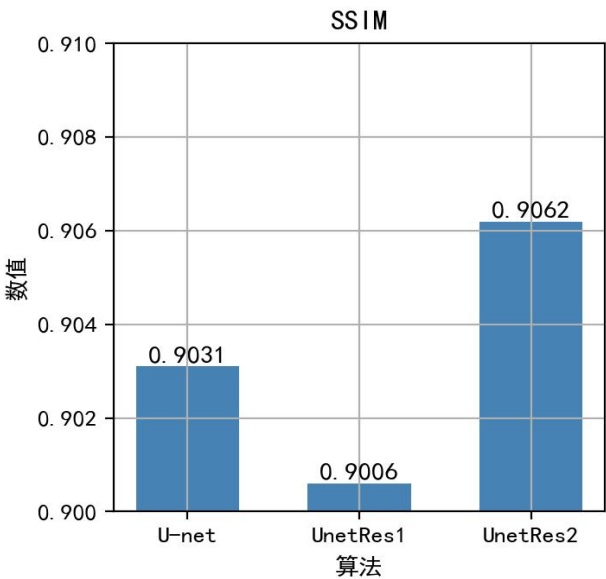


图 3-13 SSIM 柱状图

由以上实验结果可以得出结论，U-net 深度卷积网络通过其压缩和扩展路径、跳转连接等特点可以很好地提取图片中的特征并且保留一定原始图像的信息。在每层网络中加入残差学习可以一定程度上的降低训练损失，增强了梯度传播，避免随着神经网络层数的增加出现训练退化问题，且残差网络中输入端跳转的卷积层数越多效果越好。

第 4 章 总结与未来工作

本章总结了本文完成的任务和实验内容，并且对未来工作进行了叙述。

4.1 工作总结

本文以油气勘探为背景，首先探讨了地震勘探方法的原理和优势，了解了构建速度模型进行地震速度反演的重要性，接着详细分析了传统反演方法的劣势和局限，而数据驱动的深度卷积网络算法可以有效提高速度模型建立的准确性，所以着手于研究深度卷积网络的网络架构和优化算法。本文从以下的几个方面进行了探究：

1. 本文将地震速度反演问题可以看成是一个地震信号到速度的多输出回归问题，本论文利用卷积网络来解决这一回归问题。本文实现了一种有监督的端到端的深度学习方法，即 U-net 网络，其基于 FCN 构建出了左右对称的压缩路径和扩展路径，同时为了保留原始图形的部分信息进行了左右越级连接操作，并进一步选取损失函数和优化器进行参数学习。通过设置合适的学习率、迭代次数和最小批次进行批训练得到训练好的速度模型。

2. 本文在 U-net 基础上融合了 V-net 网络的结构特点，对于每个卷积层加入了不同程度的残差网络学习，分别称为 UnetRes1 和 UnetRes2，即输入端信息直接跳转到多层卷积层后，通过学习残差来优化网络，简化学习。

3. 本文通过损失函数图像、峰值信噪比和结构相似性来定量衡量预测结果。依次对三种卷积网络进行对比，得出结论：U-net 深度卷积网络通过其压缩和扩展路径、跳转连接等特点可以很好地提取图片中的特征并且保留一定原始图像的信息。在每层网络中加入残差学习可以一定程度上的降低训练损失，避免随着神经网络层数的增加出现训练退化问题，且残差网络中输入端跳转的卷积层数越多效果越好。

4.2 未来工作

本文认为，利用训练好的网络去测试其他更加复杂或者真实的模型是困难的，本论文提出的方法性能依赖于数据集，也就是说，用于预测的监督学习网络受限于训练

数据集的选择，并且训练所需的数据集取决于许多因素，此外在两种不同类型的速度模型之间具有相对较弱的相似分布。另一方面，训练过程所消耗的时间较长。

所以未来工作可以基于有限的开放数据集，使用生成式对抗网络（GAN）来建立更复杂、更真实的速度模型，然后我们可以用这些复杂的数据集来训练网络，并通过迁移学习将训练好的网络应用于真实的现场数据。

参考文献

- [1] Woodward, M J, Nichols D, et al. A decade of tomography[J]. Geophysics, 2018, 73(5): 5-11.
- [2] Guo Q, Zhang H, Han F, et al. Prestack seismic inversion based on anisotropic Markov random field[J]. IEEE Transactions on Geoscience and Remote Sensing, Feb. 2018, 56(2): 1069-1079.
- [3] Biondi B, Almomin A. Simultaneous inversion of full data bandwidth by tomographic full-waveform inversion[J]. Geophysics, 2014, 79(3): 129-140.
- [4] Pratt R G, Shin C, Hick G J. Gauss-Newton and full Newton methods in frequency-space seismic waveform inversion[J]. Geophys. J. Int., May 1998, 133(2): 341-362.
- [5] Zhang Q, Hui Z, Li Q, et al. Robust source-independent elastic full-waveform inversion in the time domain[J]. Geophysics, 2015, 81(2): 13-28.
- [6] Zhao, T., V. Jayaram, A. Roy, et al. A comparison of classification techniques for seismic facies recognition[J]. Interpretation, 2015, 3(4): 29-58.
- [7] Hall B. Facies classification using machine learning[J]. The Leading Edge, 2016, 35: 906-909.
- [8] Guillen P, Larrazabal G, Gonzalez G, et al. Supervised learning to detect salt body[C]// 2015 SEG ' s International Exposition and 85th Annual Meeting in New Orleans, Louisiana. 2015: 1826-1829.
- [9] Wang W, Yang F, Ma J. Automatic Salt Detection with Machine Learning[C]// 80th EAGE Conference and Exhibition 2018, EAGE, Extended Abstracts. 2018: 9-12.
- [10] Araya-Polo M, Dahlke T, Frogner C, et al. Automated fault detection without seismic processing[J]. The Leading edge, 2017, 36: 208-214.
- [11] Araya-Polo M, Jennings J, Adler A, et al. Deep-learning tomography[J]. The Leading

- Edge, 2018, 37: 58-66.
- [12] Yang F, Ma J. Deep-learning inversion: a next generation seismic velocity-model building method[J]. Geophysics, 2019, 84(4): 583-599.
- [13] Li S, Liu B, Ren Y, et al. Deep-Learning Inversion of Seismic Data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(3).
- [14] Di H, Chen X, Maniar H, et al. Seismic Acoustic Impedance Estimation by Learning from Sparse Wells via Deep Neural Networks[C]// 82nd EAGE Annual Conference & Exhibition. European Association of Geoscientists & Engineers, 2020, 2020(1): 1-5.
- [15] Sun J, Niu Z, Innanen K A, et al. A theory-guided deep-learning formulation and optimization of seismic waveform inversion[J]. Geophysics, 2020, 85(2): 87-99.
- [16] Sun J, Niu Z, Innanen K A, et al. A theory-guided deep learning formulation of seismic waveform inversion[M]//SEG Technical Program Expanded Abstracts 2019. Society of Exploration Geophysicists, 2019: 2343-2347.
- [17] Zhang Z, Lin Y. Data-Driven Seismic Waveform Inversion: A Study on the Robustness and Generalization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(10): 6900-6913.
- [18] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]// International Conference on Neural Information Processing Systems. MIT Press, 2014: 2672-2680.
- [19] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. Springer International Publishing, 2015, 9351: 234-241.
- [20] Milletari F, Navab N, Ahmadi S A. V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation[C]// 2016 Fourth International Conference on 3D Vision (3DV). IEEE, 2016: 565-571.
- [21] Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Networks.[J]. Science, 2006, 313(5786): 504-507.

- [22]Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

致 谢

四年的时光飞速逝去，回首大学生活，这是我人生中最美好的一段日子。在这四年独自异地的求学之路中，我经历了艰难挣扎的挫折，但同时也收获了很多的帮助、关心和鼓励。在此刻，我由衷的表示感谢。

我要感谢我的母校南师大和计算机与电子信息学院，他们给我提供了求知的可能和探索未知的勇气，自始至终都仿佛有一种无形的力量不断督促我勇敢前行。

我要感谢我的毕设导师许建华老师，许建华老师十分的耐心，在毕业设计选题、文献阅读、实验、论文撰写等方面都给予了我详细的指导，使我一个几乎没有科研经验的新手顺利完成了基于深度卷积网络的地震速度反演方法研究，并且向我打开了深度学习的大门，激发了我浓厚的兴趣与好奇心。同时我要感谢班主任王琼老师，和他的每次沟通都能为我指点迷津、让我受益匪浅；感谢我的大创导师张国强老师，通过完成了长达一年时间的项目，让我学习到了很多书本之外的知识和技能。

我要感谢计电院 2 班的王家雨、张渝茜、姚逸婷、吴若婕，我们曾相互陪伴与帮助，共同攻克大大小小的难题。感谢何潼川学长、张倩学姐曾给予过无数次学业、生活上的建议和启迪。感谢电自院的别亚楠，大学四年里，永远像榜样一样陪伴着我一起成长。感谢我的室友黄洁沁、夏瑜、顾董天骄，有你们的包容和关心，我才能够快乐的度过这段岁月，祝福你们在今后的日子里每天都开心快乐。感谢我的爱豆华晨宇，你永远都能在我最痛苦的时候带给我快乐与慰藉、让我不再孤单。感谢我的前男友四年的陪伴与付出，虽然我们没能走到最后，但他让我拥有了积极乐观的心态和坚持到底永不放弃的精神。

最后我要把最诚挚的感谢留给一直都在默默支持我的家人，他们永远都不求回报的倾尽所有为我付出，在我无助茫然的时候指明方向，在我崩溃挣扎的时候给我鼓励，陪我走过了大学四年无数个艰难的阶段。感谢父亲和母亲为我阻挡了风雨和艰险，让我茁壮成长！

感谢其他关心、支持和帮助过我的人！

本科期间主要研究成果

完成项目：

- [1] 黄艺冉，朱权，范世越，张乙朋，姚逸婷. 大学生创新训练项目. 南京师范大学，2020~2021，0.3 万.